QI TECH BOOT CAMP

HACKATHON QI TECH 2026 · RISK SOLUTIONS

Motor antifraude de Pix

Regras que um atendente consegue explicar, calibradas num simulador independente, com machine learning pronto em modo sombra.

Pedro H. S. Prestes · Laura Pazini Medeiros

Hackathon-Anti-Fraud-Pix

PONTO DE PARTIDA

Não **reinventamos a roda**

Somos iniciantes em antifraude. Em vez de inventar limites da nossa cabeça, fomos atrás de quem já estudou e mediu.

01

Literatura

Branca e cinzenta: detecção estatística de fraude, aprendizado com rótulo que chega atrasado e a taxonomia dos golpes de Pix no Brasil.

02

Normas do Banco Central

O limite noturno de R$ 1.000 e os fatores de suspeita do Regulamento do Pix: idade da conta que recebe, recorrência entre quem paga e quem recebe.

03

Simulador aberto

O PixSim: tráfego e golpes de Pix gerados por outros autores e calibrados com dados públicos do BCB.

Daí saiu uma arquitetura em que **cada regra ou modelo entra e sai sem mexer no resto**, e cada parâmetro pode ser recalibrado para o perfil de clientes de cada banco.

A literatura é de **cartão**. O problema é **Pix**.

CARTÃO DE CRÉDITO

- Contestação e estorno fazem parte da rotina
- Décadas de dados rotulados, com bases públicas
- Golpe típico: cartão clonado, a compra é do fraudador

PIX

- Instantâneo, 24 horas: o dinheiro some em segundos
- Nenhuma base real aberta, só relatórios agregados do BCB
- Golpe típico: a própria vítima, enganada, faz o Pix

A pergunta do projeto: **as técnicas clássicas ainda funcionam no Pix?** Medimos, em vez de supor.

QITECH BOOT CAMP

Todas as regras rodam, **a mais severa vence**

Pix chega
POST /pix/transaction

→

Histórico
do pagador, do aparelho e de quem recebe

→

15 regras
cada uma diz: nada, pedir confirmação ou barrar

→

approved · segue

two_factor_required · o cliente confirma

rejected · barrado

Duas dúvidas não viram bloqueio

Barrar exige um sinal extremo ou uma combinação que descreve um golpe conhecido: conta tomada, conta laranja.

Toda decisão tem motivo

A resposta lista os motivos em português, do mais grave ao mais leve, com os números usados e a versão das regras.

QITECH BOOT CAMP

Uma regra só entra se **tiver um motivo**

01

Pega fraude

No simulador independente, barra golpes e paga o incômodo que causa nos clientes bons.

02

Segue o BCB

Limite noturno, idade da conta que recebe: fica mesmo quando o simulador preferiria outra coisa.

03

Cobre o que o simulador não gera

Viagem impossível, fazenda de aparelhos, funil de vítimas: lá não dispara e não custa nada.

3 regras **saíram do motor** depois de medidas: fracionamento em Pix pequenos, destino que já teve Pix recusado e soma diária. Desligamos uma regra de cada vez e vimos que elas incomodavam mais clientes bons do que golpes evitavam, nos dois cenários do simulador.

Regras que um atendente **consegue explicar**

DESTINATÁRIO NOVO

COUNTERPARTY_FIRST_TIME_HIGH

Primeiro Pix para alguém, acima de R$ 1.000

Golpe manda o dinheiro para quem a vítima nunca pagou. O aluguel vai sempre para o mesmo lugar. É a regra que mais protege.

APARELHO NOVO

PROFILE_NEW_DEVICE

Celular nunca usado, a partir de R$ 200

Trocar de aparelho é o primeiro passo de quem tomou a conta de alguém. O piso poupa o cafezinho do celular novo.

RÁPIDO DEMAIS

VELOCITY_POISSON_GAMMA

Rajada improvável para o ritmo da pessoa

"Rápido demais" é diferente para cada um: comparamos a pressa de agora com o histórico do próprio cliente.

As 15 regras, com parâmetro e fonte de cada uma, estão no README e no catálogo de regras.

QITECH BOT CAMP

Os níveis de comparação de **Bolton & Hand**

NÍVEL	PERGUNTA	NO MOTOR	SITUAÇÃO
1 · Individual	Está no padrão dele?	Valor fora do perfil, rajada, aparelho novo	usado
2 · Grupo de pares	Está no padrão de quem é parecido?	Comparação com clientes do mesmo tipo e idade de conta	medido e descartado
3 · Ponto de ruptura	O comportamento mudou de repente?	Por aproximação: rajada, aparelho novo, modelo de sequência em sombra	parcial
4 · Rótulos externos	Alguém já marcou esse destino?	Fraude confirmada pelo MED marca a conta que recebe	só no backtest

Os quatro níveis são a organização da nossa pesquisa a partir de Bolton & Hand (2002).

COMO VALIDAMOS

Medir no próprio simulador seria **corrigir a própria prova**

NOSSO SIMULADOR

Gera os golpes que **nós** desenhamos, e as regras foram escritas para pegá-los: barram 98,5%. É circular.

Ficou só como **teste automático do CI**, para nenhuma mudança quebrar o que funcionava.

PIXSIM · SIMULADOR DE TERCEIROS

Golpes que não desenhamos: engenharia social, conta tomada, Pix errado, QR adulterado.

Cenário A
escolhe os parâmetros

→

Cenário B
confirma, sem ter sido usado na escolha

Critério: custo em reais, somando a fraude que passa e o incômodo causado aos clientes bons.

O que o motor **entrega**

≈3%

dos Pix **legítimos** pedem confirmação; praticamente nenhum é barrado

99%

dos golpes de **conta tomada** têm algum Pix barrado

−21%

de **prejuízo esperado** em relação a não ter motor, já contando o incômodo

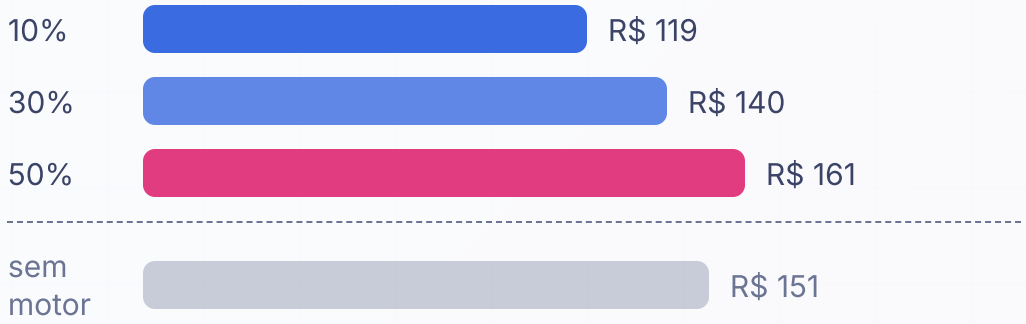
Simulador de terceiros, não Pix real: os números indicam direção e ordem de grandeza.

Engenharia social: quando **a vítima** faz o Pix

O golpista convence a vítima, e ela paga do próprio celular, dentro do próprio padrão. Quase nada parece fraude, exceto o destinatário novo.

O motor só consegue **pedir confirmação**, e uma vítima pressionada pode confirmar.

Se mais de **~40%** das vítimas confirmarem, o motor passa a custar mais do que não ter motor.



Próximo passo: 2FA que alerta sobre o golpe, segurar por algumas horas o primeiro Pix alto e olhar a conta que recebe.

QITECH BOOT CAMP

Um caminho **rápido** e um caminho **de fundo**

DENTRO DA REQUISIÇÃO · MILISSEGUNDOS

Pix
chega pela API

→

API
15 regras decidem · 5 modelos em sombra opinam

→

Resposta
decisão + motivos

↓

Postgres
Pix, análise e motivos · scores calculados pelo worker

o worker grava o score;
a API só lê o pronto

A CADA 30 SEGUNDOS · EM PARALELO

Worker
olha a rede de quem paga quem: conta que recebe de muitos e repassa logo

→

Score por conta
reputação na rede, GraphSAGE e sequência (HMM), gravado no Postgres

O mesmo código decide na **API** e no **backtest**

Motor: regras + modelos

pergunta o histórico sempre do mesmo jeito (uma "tomada" padrão)

Produção

responde pelo Postgres, com SQL

cada Pix pela API

Backtest

responde pela memória, sem HTTP e sem banco

255 mil Pix em ~100 s

Paridade: o mesmo roteiro de Pix nos dois lados dá **0 divergências** em decisão, motivos e nas 33 características calculadas.

O Base Service, **camada por camada**

IDA · O PEDIDO

middlewares → schemas → resources → controllers → **rules** (nova: o motor) → repositories → database

VOLTA · A RESPOSTA

Idempotência

Mesmo id e mesmo Pix: a mesma resposta (200). Id repetido com outro conteúdo: 409.

Banco só cresce

Só INSERT. Todo Pix fica gravado, inclusive os barrados. Dinheiro em centavos.

Logger

Toda linha com o id da requisição: dá para seguir um Pix de ponta a ponta.

113 testes

Todos pela própria API: cada regra tem um caso que passa e um que dispara.

Cinco modelos em **modo sombra**

O que é

Em todo Pix, o modelo calcula um score e registra o que **decidiria**, mas quem decide são as regras. O banco compara os dois no mesmo tráfego, sem arriscar o cliente.

Regressão logística, LightGBM e Isolation Forest no caminho rápido; GraphSAGE e HMM no de fundo.

Por que ainda não decidem

Custo com o modelo, conforme a qualidade dele (AUC):

0,99 · no simulador	16% mais barato
≈0,93	empata com as regras
0,82 · típico de dado real	7% mais caro

Ligar um modelo é **uma linha de código**. O que falta é rótulo real de fraude.

RETROALIMENTAÇÃO

Como o banco **aprende com o MED**

1 · Decide
regras + modelo

→

2 · Liquida
só o que passou

→

3 · Reclama
a vítima, no MED, dias depois

→

4 · Aprende
marca a conta que recebeu e vira rótulo

→

5 · Retreina
toda semana, desafiante × campeão

↻ volta para o passo 1

Viés de seleção

Pix barrado nunca gera reclamação. Com o modelo decidindo, **77%** das fraudes nunca viram rótulo, e o retreino aprende a esquecer o que já é barrado.

Onde roda

Só no backtest, com os atrasos reais de reporte do simulador. A API não recebe desfechos: o contrato do desafio tem só POST e GET.

Decisões **documentadas e navegáveis**

33

ADRs

Cada decisão com o contexto, as alternativas descartadas e o preço de cada uma.

C4

Diagramas

Do contexto aos componentes, mais o backtest e o ciclo de retroalimentação.

AI

Pronto para agentes

`AGENTS.md` e `llms.txt` dão o contexto direto: menos tokens para uma IA entender o projeto.

Log

CHANGELOG

Toda mudança registrada com o porquê, de pessoa ou de agente.

Do simulador para **dados reais**

01	**Rota de desfechos**: o MED e o DICT voltando para o motor como rótulo
02	**Inferência de rejeitados**: corrigir o treino pelas fraudes que o motor barrou
03	**Janelas em streaming** (Kafka + Flink + Redis) para escalar o histórico
04	**Scores externos** no caminho de fundo: bureaus e listas de contas suspeitas
05	**Dados de sessão** (digitação, chamada em andamento) para o modelo de sequência

Bibliografia

[1] QI Tech. *Desafio Antifraude Pix* e slides do Hackathon QI Tech 2026.

[2] Pesquisa QITech (documento interno do time).

[3] Bolton, R. J.; Hand, D. J. (2002). Statistical fraud detection: a review. *Statistical Science* 17(3).

[4] Pizzolato et al. (2025). A taxonomy of Pix fraud in Brazil. arXiv:2511.20902.

[5] Zeimarani, B. et al. (2026). PixSim: a calibrated open-source simulator of instant-payment fraud. github.com/BashirZeimarani/pixsim_public.

[6] Dal Pozzolo, A. et al. (2015). Calibrating probability with undersampling for unbalanced classification. IEEE SSCI.

[7] Dal Pozzolo, A. et al. (2018). Credit card fraud detection: a realistic modeling and a novel learning strategy. IEEE TNNLS 29(8).

[8] Dal Pozzolo, A. et al. (2014). Learned lessons in credit card fraud detection from a practitioner perspective. ESWA 41(10).

[9] Lucas, Y. et al. (2019). Multiple perspectives HMM-based feature engineering for credit card fraud detection. ACM SAC.

[10] Carcillo, F. et al. (2018). SCARFF: a scalable framework for streaming credit card fraud detection with Spark. *Information Fusion* 41.

[11] Banco Central do Brasil. Resolução BCB nº 142/2021; Instrução Normativa BCB nº 512/2024.

[12] Banco Central do Brasil. Regulamento do Pix, arts. 37 e 39-B.

[13] Iglewicz, B.; Hoaglin, D. C. (1993). *How to Detect and Handle Outliers*. ASQC.

[14] Platt, J. C. (1999). Probabilistic outputs for support vector machines. *Advances in Large Margin Classifiers*.

[15] Ke, G. et al. (2017). LightGBM: a highly efficient gradient boosting decision tree. NeurIPS 30.

[16] Liu, F. T.; Ting, K. M.; Zhou, Z.-H. (2008). Isolation forest. IEEE ICDM.

[17] Hamilton, W. L.; Ying, R.; Leskovec, J. (2017). Inductive representation learning on large graphs. NeurIPS 30.

[18] Rabiner, L. R. (1989). A tutorial on hidden Markov models. *Proceedings of the IEEE* 77(2).

[19] Gelman, A. et al. (2013). *Bayesian Data Analysis*, 3ª ed. CRC Press.