# Motor antifraude de Pix: relatório técnico

Hackathon QI Tech 2026 · Risk Solutions

Pedro H. S. Prestes  Laura Pazini Medeiros

18 de outubro de 2026

## Sumário

**Resumo executivo** **3**

**1 O problema** **4**
1.1 O Pix e a decisão em tempo real . . . 4
1.2 As três decisões . . . 4
1.3 Fricção × fraude . . . 4
1.4 O MED e o atraso do rótulo . . . 4
1.5 O enunciado . . . 5

**2 Fundamentos teóricos** **6**
2.1 Detecção de fraude: regras × modelos e os níveis de Bolton & Hand . . . 6
2.2 Estatística robusta: mediana, MAD e z robusto sobre $\log(\text{valor})$ . . . 6
2.3 Contagens: Poisson, conjugada Gamma e a preditiva binomial negativa . . . 7
2.4 Distância de haversine e viagem impossível . . . 7
2.5 Tipologias de golpe e regras compostas . . . 7
2.6 Grafos: funil, dispersão, vizinhança de dois saltos e GraphSAGE . . . 8
2.7 Sequências: HMM discreto, Baum–Welch e verossimilhança como anomalia . . . 8
2.8 Regressão logística, calibração de Platt, *gradient boosting* e Isolation Forest . . . 9
2.9 Desbalanceamento, custo assimétrico e P@$k$ . . . 9
2.10 PSI e deriva; rótulos atrasados; viés de seleção; *champion/challenger* e *shadow mode* . . . 10

**3 Arquitetura** **11**
3.1 Camadas do Base Service . . . 11
3.2 *Hot path* × *cold path* . . . 11
3.3 Diagramas C4 . . . 11
3.4 Contrato da API . . . 16
3.5 Modelo de dados . . . 16

**4 Implementação** **17**
4.1 O motor: *snapshot*, contexto, `HistoryPort` e decisão . . . 17
4.2 Catálogo de regras, parâmetros e justificativas . . . 17
4.2.1 Limite: “passou do teto?” . . . 17
4.2.2 Velocity: “rápido demais?” . . . 18
4.2.3 Montante: “somou demais?” . . . 18
4.2.4 Perfil: “está no padrão do cliente?” . . . 18
4.2.5 Contraparte: “quem recebe é confiável?” . . . 19
4.2.6 Tipologia: combinações que descrevem um golpe . . . 19
4.2.7 Regras descartadas . . . 19

4.3 Modelos servidos em Python puro . . . 20
4.4 O worker (*cold path*) . . . 21
4.5 Backtest em lote e paridade . . . 21
4.6 Mapa do código . . . 21

**5 Metodologia de validação** **23**
5.1 Por que o nosso simulador é só *fixture* de CI . . . 23
5.2 O PixSim . . . 23
5.3 Escala reduzida . . . 23
5.4 Adaptador: o que foi mapeado, inventado e não existe . . . 24
5.5 Mundos A e B; perspectiva do banco pagador . . . 24
5.6 Métricas . . . 24
5.7 Avaliação nos dois sentidos . . . 25
5.8 Calibração por custo (mundo A escolhe, mundo B confirma) . . . 25
5.9 Alinhamento com a metodologia do PixSim e comparação com o artigo . . . 25
5.10 Vazamento de dados e vieses do gerador . . . 26
5.11 O que o PixSim não gera . . . 26

**6 Resultados no PixSim** **28**
6.1 Fricção em legítimos . . . 28
6.2 Captura por tipologia . . . 28
6.3 Custo esperado . . . 28
6.4 P@$k$ diário . . . 29
6.5 Calibração: efeito de cada parâmetro e configuração final . . . 29
6.6 Modelos em *shadow* . . . 30
6.7 Rótulos atrasados . . . 31
6.8 Retroalimentação pelo MED . . . 32
6.9 Peer group: medido e descartado . . . 32
6.10 Latência . . . 32
6.11 Deriva das características . . . 33
6.12 Contribuição de cada regra (ablação) . . . 33
6.13 Cascata de valor . . . 34
6.14 Sensibilidade à qualidade do escorer . . . 35

**7 Limitações e trabalhos futuros** **36**

**8 Como reproduzir** **37**

**9 Perguntas prováveis da banca** **38**
9.1 O problema e a decisão . . . 38
9.2 Regras e calibração . . . 38
9.3 Validação . . . 39
9.4 Modelos e retroalimentação . . . 40
9.5 Engenharia . . . 40
9.6 Próximos passos e processo . . . 40

**Referências** **41**

## Resumo executivo

**Problema.** O desafio do Hackathon QI Tech 2026 pede uma API que receba um Pix antes de ele sair e responda, com motivo, uma de três decisões: `approved`, `two_factor_required` (2FA) ou `rejected`. Não há rótulo de fraude, nem analista, nem consulta externa no caminho da decisão. Bloquear cliente bom também é prejuízo; deixar passar fraude custa o valor do Pix.

**Solução.** Um motor de regras explícitas e explicáveis sobre o histórico que a própria API acumula (Python 3.11, FastAPI, PostgreSQL 16, Docker Compose). Cada Pix atravessa 15 regras (limite, velocidade, perfil, contraparte e tipologias de golpe), e a decisão final é a mais severa entre as que dispararam; todos os disparos vão para `metadata.reasons`, com os números usados em `metadata.signals`. Sinais estatísticos (z robusto de $\log(\text{valor})$, preditiva Poisson–Gamma, haversine) entram como regras comuns, em Python puro. Um segundo caminho, assíncrono (*cold path*), calcula a reputação de rede de cada conta de destino (funil, dispersão, vizinhança de dois saltos) e dois modelos aprendidos (GraphSAGE e HMM). Cinco modelos rodam em *shadow*: calculam, gravam e nunca mudam a decisão.

**Como validamos.** O nosso simulador gera as fraudes que nós mesmos desenhamos, e as regras procuram exatamente esses padrões; sobre ele a captura chegava a cerca de 92%, o que é circular. Por isso toda métrica deste relatório vem do PixSim [5], um simulador de terceiros, aberto e calibrado com dados abertos do Banco Central. O nosso simulador ficou como *fixture* de CI. Os parâmetros foram escolhidos em um mundo do PixSim (A) pelo custo esperado ponderado e confirmados em outro (B).

**Números principais** (PixSim, mundo A, 30 dias avaliados, 125.518 Pix legítimos, 986 eventos de fraude; *fonte:* `validacao-pixsim.md` *e* `calibracao.md`):

| Métrica | Valor |
|---|---|
| Legítimos aprovados / 2FA / reprovados | 97,03% / 2,97% / 0,00% |
| Pix de vítima barrados (2FA ou reprovação) | 50,7% |
| Eventos de fraude com ao menos um Pix de vítima barrado | 584 de 986 (conta tomada 98,6%; engenharia social 56,6%; QR adulterado 27,9%; Pix errado 9,9%) |
| Custo ponderado por 1.000 Pix (falso bloqueio a R$ 50 + 2%) | R$ 109,61 (mundo A); R$ 118,82 (mundo B), contra R$ 127,26 antes da calibração e R$ 153,51 com as 18 regras de antes do descarte (mundo B) |
| Latência do motor em memória (backtest) | P50 0,33 ms, P95 0,60 ms, P99 0,84 ms (2.710 Pix/s) |
| Modelos treinados no PixSim A, testados no B (AUC) | regressão logística 0,990; LightGBM 0,989; GraphSAGE de nó 0,92 |
| Regras + LightGBM em *shadow* pedindo 2FA (mundo B) | 80,9% dos Pix de vítima barrados; R$ 99,42 por 1.000 Pix |

**Limitações.** Tudo é dado sintético: "métricas no PixSim" medem fricção e custo *relativo* entre configurações, não eficácia em produção. Os mundos A e B vêm do mesmo gerador (só muda a semente). O PixSim não tem geolocalização, então as regras geográficas ficam inertes na validação. A escala é reduzida (5.025 contas). Os rótulos de produção chegariam com atraso pelo MED, e a rota de desfechos não faz parte do contrato do enunciado. A seção 7 detalha o que falta.

# 1 O problema

## 1.1 O Pix e a decisão em tempo real

O Pix é o sistema de pagamentos instantâneos do Banco Central do Brasil (BCB). A liquidação é praticamente imediata e irreversível do ponto de vista do pagador, o que desloca a defesa para *antes* da saída do dinheiro: a instituição pagadora precisa decidir em segundos, com o cliente esperando, sem analista humano e sem consulta externa pesada [1]. Três tensões moldam o desenho:

| Tensão | Consequência no desenho |
|---|---|
| **Tempo.** A decisão sai em poucos segundos. | Tudo o que a regra precisa está no payload ou no banco próprio. Nenhuma chamada HTTP no caminho da decisão (ADR 0002). |
| **Histórico.** Um Pix sozinho diz pouco; o sinal está na comparação com o passado do pagador, do destino e do aparelho. | Todo Pix recebido é gravado, inclusive os reprovados, com índices por janela de tempo (ADR 0009). |
| **Fricção.** Bloquear cliente bom é prejuízo. | Existe o meio-termo `two_factor_required`; cada parâmetro é calibrado e justificado. |

## 1.2 As três decisões

| Status | Significado | Quando |
|---|---|---|
| `approved` | O Pix segue sem fricção. | Nenhuma regra disparou. |
| `two_factor_required` | O cliente confirma que é ele (2FA). | Há dúvida: o sinal isolado ocorre também com cliente bom. |
| `rejected` | O Pix não sai. | O risco é claro: sinal extremo ou tipologia de golpe. |

Um 2FA custa pouco ao cliente legítimo (um toque) e é eficaz contra quem não tem o segundo fator, mas é ineficaz quando a própria vítima, coagida ou enganada, confirma: é o caso da engenharia social, em que o dispositivo e as credenciais são legítimos. Por isso o desenho olha também a *conta de destino*, não apenas o pagador.

## 1.3 Fricção $\times$ fraude

O problema é de decisão sob custo assimétrico: uma fraude aprovada custa o valor do Pix; um cliente bom reprovado custa atendimento, abandono e *churn*; um 2FA a um cliente bom custa atrito pequeno. Acurácia é inútil quando mais de 99,9% das transações são legítimas (um classificador que responde "tudo legítimo" acerta 99,9%). Daí a escolha de métricas deste trabalho: custo esperado em reais e precisão nos $k$ alertas mais suspeitos do dia (P@$k$), na seção 5.6.

## 1.4 O MED e o atraso do rótulo

O Mecanismo Especial de Devolução (MED) é o processo pelo qual a vítima contesta um Pix e o valor pode ser recuperado. Para a ciência de dados, o MED tem uma consequência: o *rótulo* de fraude só existe depois que a vítima reporta, dias depois do Pix. No PixSim, o atraso de reporte nas 1.380 fraudes de vítima do mundo A tem mediana de 2,1 dias e p90 de 17,5 dias, e 1,8% nunca são reportadas (*fonte:* `validacao-pixsim.md`*, "Rótulos atrasados"*). Modelos treinados em produção veem, no instante do treino, as fraudes mais recentes ainda rotuladas como legítimas; a seção 2.10 e a seção 6.7 tratam do efeito.

## 1.5 O enunciado

O desafio (transcrição fiel em `docs/01-contexto/enunciado.md`) pede: `POST /pix/transaction` recebe o Pix e devolve exatamente `{key, status, metadata}`, com `status` em `approved`, `rejected` ou `two_factor_required` e `metadata` livre; `GET /pix/transaction/{id}` devolve a análise gravada. Entram o banco próprio com o histórico de tudo o que chegou, as regras e os testes, o README e o ponto de partida do Base Service; ficam de fora onboarding, front-end e outras APIs. A política antifraude é livre, "desde que expliquem o porquê". O payload traz valor em centavos, data com fuso, conta de origem e destino (agência, conta, data de abertura, documento do titular, ISPB do destino), aparelho, canal, IP e geolocalização opcional. Não há rótulo de fraude.

Garantias que o time assumiu (`docs/01-contexto/problema.md`): todo Pix recebido fica gravado e consultável; o mesmo Pix enviado duas vezes não gera duas análises; a decisão é reprodutível (mesmo histórico e mesmo Pix, mesma decisão); dinheiro é inteiro em centavos; nenhuma decisão sai sem motivo. Ficam fora do escopo mover o dinheiro, o fluxo do 2FA, regras configuráveis sem código, modelo de ML decidindo (os modelos rodam só em *shadow*), consultas a bases externas e a retroalimentação na API: a API não recebe desfechos (MED, contestação, resultado do 2FA), porque o contrato do enunciado só tem `POST` e `GET`. A retroalimentação é simulada no backtest sobre o PixSim (seção 6.8), e a rota de desfechos fica como primeiro passo de produção (ADR 0032).

# 2 Fundamentos teóricos

Cada subseção responde a três perguntas: o que é o método, por que serve aqui e qual é a limitação. As referências numeradas estão na seção "Referências"; os métodos clássicos de aprendizado de máquina (regressão logística, LightGBM, Isolation Forest, GraphSAGE, HMM) são descritos na pesquisa interna do time [2], que é a fonte consultada para este capítulo.

## 2.1 Detecção de fraude: regras × modelos e os níveis de Bolton & Hand

**O que é.** Bolton e Hand [3] organizam a detecção estatística de fraude em níveis de comparação, que a pesquisa do time resume em quatro:

1. *individual*: o comportamento histórico do próprio cliente (valores típicos, locais frequentes);
2. *grupo de pares* (*peer group analysis*): o cliente contra clientes semelhantes;
3. *ponto de ruptura* (*break point*): o instante em que o padrão de uma conta muda abruptamente;
4. *rótulos externos*: listas de entidades marcadas como suspeitas.

**Por que serve aqui.** Sem rótulos, a abordagem é não supervisionada ou de limiar sobre desvio do perfil. O nível 1 vira `PROFILE_AMOUNT_ROBUST_Z` e `VELOCITY_POISSON_GAMMA`; o nível 3, a combinação de aparelho novo com valor atípico (tipologia de conta tomada); o nível 4, a reputação *derivada* do próprio histórico, sem lista externa, foi implementado como `COUNTERPARTY_FLAGGED` e descartado pela ablação (seção 4.2.7); a versão com desfecho confirmado pelo MED (`COUNTERPARTY_CONFIRMED_FRAUD`) existe só no backtest (seção 6.8). O nível 2 também foi implementado, medido e descartado (seção 6.9).

**Regras × modelos.** Regras são explícitas, auditáveis e dão um motivo por disparo, o que o enunciado exige; modelos de *gradient boosting* continuam o padrão da indústria em dados tabulares, mas precisam de rótulos. A pesquisa recomenda a pilha em camadas: regras e listas na primeira linha (0,5 a 2 ms), *ensembles* no caminho síncrono (2 a 8 ms), redes sequenciais e de grafos fora dele. Este projeto adota exatamente essa separação: regras decidem, modelos ficam em sombra.

**Limitação.** Regras codificam hipóteses nossas; sem rótulo real não se mede sua taxa de erro em produção, só sobre simuladores.

## 2.2 Estatística robusta: mediana, MAD e z robusto sobre $\log(\text{valor})$

**O que é.** Para uma amostra $x_1, \ldots, x_n$, a mediana $m$ e o desvio absoluto mediano $\text{MAD} = \text{mediana}_i\,|x_i - m|$ são estimadores de posição e escala com ponto de ruptura de 50%: metade das observações pode ser arbitrária sem derrubá-los. Multiplicado por $1{,}4826 = 1/\Phi^{-1}(3/4)$, o MAD é consistente com o desvio-padrão de uma normal. O z robusto de um valor $a$ do pagador é

$$z = \frac{\ln a - m}{\max(1{,}4826 \cdot \text{MAD},\ s_{\min})}, \qquad m,\ \text{MAD calculados sobre } \{\ln a_i\} \text{ dos últimos 30 dias,}$$

com piso de escala $s_{\min} = 0{,}25$ (`RULE_PROFILE_MIN_SCALE_PERCENT = 25`) e histórico mínimo de 5 Pix (implementação em `robust_z` e `amount_z`).

**Por que serve aqui.** Valores de Pix são multiplicativos ("o dobro do usual" pesa igual em R$ 20 e em R$ 2.000), então o logaritmo simetriza. O histórico de cada pagador é pequeno e um Pix grande antigo não pode inflar a escala e esconder o próximo, o que acontece com média e desvio-padrão. O piso evita divisão por zero quando o histórico é idêntico (MAD = 0). A análise 1 de `analises.md` mediu, no mundo A do PixSim, assimetria mediana de 0,03 de $\ln(\text{valor})$ por pagador, 85,4% dos 3.192 pagadores com |assimetria| $< 0{,}5$ e QQ a no máximo 0,01 da normal (em unidades de z), o que sustenta o uso do logaritmo.

**Limitação.** Pagador sem histórico (menos de 5 Pix em 30 dias) não tem z; ele fica coberto pelas regras de payload e de velocidade fixa. O grupo de pares que o cobriria foi descartado por não render captura no PixSim.

## 2.3 Contagens: Poisson, conjugada Gamma e a preditiva binomial negativa

**O que é.** Se as chegadas de Pix de um pagador seguem um processo de Poisson de taxa $\lambda$ (por hora), a contagem em uma janela de $w$ horas é $N \mid \lambda \sim \text{Poisson}(\lambda w)$. A taxa é incerta; com prior conjugado $\lambda \sim \text{Gamma}(\alpha, \beta)$ (forma e taxa) e $n$ eventos observados em uma exposição de $E$ horas, a posteriori é $\text{Gamma}(\alpha + n,\ \beta + E)$. A contagem futura na janela $w$ tem a *preditiva* binomial negativa:

$$P(N = j) = \frac{\Gamma(j + a)}{\Gamma(a)\, j!}\, p^a\, (1 - p)^j, \qquad a = \alpha + n, \quad p = \frac{\beta + E}{\beta + E + w}.$$

O sinal da regra é a **cauda** $P(N \geq k) = 1 - \sum_{j<k} P(N = j)$, em que $k$ é o número de tentativas na janela *incluindo o Pix atual* (`negative_binomial_tail`). Os valores adotados: janela de 60 min, retrospecto de 30 dias, prior $\alpha = 1$, $\beta = 24$ (prior de 1 Pix por dia: $\alpha/\beta = 1/24$ por hora), exposição mínima de 24 h; dispara 2FA com cauda $< 30$ ppm ($3 \times 10^{-5}$).

**Por que serve aqui.** Dá um número comparável entre pagadores muito diferentes: quatro Pix numa hora é normal para quem faz um por hora e improvável para quem faz um por semana, sem um corte fixo por pessoa. Com pouco histórico, o prior regulariza a taxa; por isso a regra exige 24 h de exposição, e o pagador novo fica com `VELOCITY_SOURCE_COUNT`.

**Verificação de dispersão.** A pesquisa recomenda comparar variância e média e trocar por binomial negativa se houver super-dispersão. A análise 2 de `analises.md` mediu, no PixSim, índice de dispersão mediano de 1,01 por hora e 1,03 por dia, com 0,0% (hora) e 2,8% (dia) dos pagadores acima de 1,5, contra 0,0% e 1,2% em contagens Poisson sorteadas com a mesma média: a super-dispersão intra-pagador não passa do ruído amostral. A Poisson–Gamma continua útil porque a *taxa* de cada pagador é incerta, o que alarga a cauda da preditiva.

**Limitação.** Supõe taxa constante (sem sazonalidade horária ou semanal) e chegadas independentes.

## 2.4 Distância de haversine e viagem impossível

**O que é.** A distância ortodrômica entre dois pontos de latitude $\varphi$ e longitude $\lambda$ numa esfera de raio $R = 6371$ km é

$$d = 2R \arcsin \sqrt{\sin^2 \frac{\Delta\varphi}{2} + \cos\varphi_1 \cos\varphi_2 \sin^2 \frac{\Delta\lambda}{2}}.$$

A velocidade implícita é $v = d / \max(\Delta t_{\text{h}},\ 1/60)$, com piso de um minuto para não dividir por zero quando dois Pix têm o mesmo instante.

**Por que serve aqui.** Dois Pix com geolocalização a 50 km ou mais um do outro e velocidade implícita acima de 900 km/h (um avião comercial) indicam sessão em outro aparelho ou localização falsa.

**Limitação.** A geolocalização é opcional no contrato; sem ela, a regra não dispara. O PixSim não gera geolocalização, então ela não foi exercitada na validação externa.

## 2.5 Tipologias de golpe e regras compostas

**O que é.** Pizzolato et al. [4] fazem uma taxonomia de 15 metodologias de ataque no Pix no Brasil (revisão da literatura mais entrevistas), apontando autenticação multifator, monitoramento comportamental e detecção por IA como mitigações. Uma *tipologia* é a combinação de sinais que descreve um golpe conhecido.

**Por que serve aqui.** Sinais isolados (aparelho novo, valor alto, viagem) ocorrem com cliente bom e pedem 2FA; juntos, descrevem tomada de conta e justificam reprovar. Dois 2FA *não* somam uma reprovação: só uma tipologia explícita combina sinais (ADR 0018). Ativas: conta tomada e conta laranja (mula).

O fracionamento (`TYPOLOGY_SPLITTING`) foi implementado e descartado pela ablação no PixSim (seção 4.2.7).

**Limitação.** Cada tipologia é uma hipótese sobre como o golpe se parece; se o simulador ou o fraudador real desenha o golpe de outro jeito, a regra cai a zero (a mula do PixSim é uma conta antiga, não recém-aberta).

## 2.6 Grafos: funil, dispersão, vizinhança de dois saltos e GraphSAGE

**O que é.** O Pix forma um grafo dirigido pagador $\rightarrow$ destino. A pesquisa descreve dois padrões de conta laranja: *funil* (várias contas pagando quase ao mesmo tempo a uma conta centralizadora) e *dispersão* (a conta recebe e repassa logo em seguida a várias contas). Uma rede neural de grafos (GNN) atribui uma "reputação de rede" a cada conta, calculada fora do caminho síncrono e consultada já pronta.

*Reputação por SQL (`graph_sql`).* O worker calcula cinco características por conta de destino (pagadores distintos em 24 h $n_p$; destinos distintos para onde repassou em 6 h $n_d$; pagadores que também pagaram destinos reprovados, a vizinhança de dois saltos $n_h$; valor recebido em 24 h $v$, em centavos; idade da conta idade) e as combina com pesos fixos, sem treino:

$$\text{logit} = -4{,}0 + 1{,}2\ln(1+n_p) + 1{,}5\ln(1+n_d) + 1{,}0\ln(1+n_h) + 0{,}3\ln\!\left(1+\tfrac{v}{100.000}\right) + 1{,}0\cdot\mathbb{1}[\text{idade} < 30], \qquad s = \sigma(\text{logit}).$$

O logaritmo amortece caudas pesadas, para que um funil enorme não sature sozinho (`GRAPH_RISK_*` em `src/constants.py`; `src/worker/models/scoring.py`).

*GraphSAGE.* Para cada nó $v$ e camada $\ell$, agrega-se a média dos vizinhos *amostrados* $\mathcal{N}_s(v)$ (no máximo 10, escolhidos por amostragem determinística semeada pelo nó):

$$h_v^{(\ell)} = \text{ReLU}\left( W_{\text{self}}^{(\ell)}\, h_v^{(\ell-1)} + W_{\text{neigh}}^{(\ell)}\, \frac{1}{|\mathcal{N}_s(v)|} \sum_{u \in \mathcal{N}_s(v)} h_u^{(\ell-1)} + b^{(\ell)} \right), \qquad s_v = \sigma(w^\top h_v^{(2)} + b).$$

Duas camadas, dimensão oculta 16, sete características de nó (log do grau de entrada e de saída, log dos valores de entrada e de saída, log da menor idade de conta, fração de pagadores novos, log da dispersão). É indutivo: o mesmo modelo pontua nós que não viu no treino.

**Por que serve aqui.** A pesquisa insiste que olhar só o pagador é inútil quando a vítima é coagida (os dados do dispositivo são legítimos); a conta de destino é o que denuncia.

**Limitação.** Inferência de grafo não cabe na latência síncrona, então o score tem atraso de até um ciclo do worker (30 s). O rótulo de nó `is_mule` do PixSim é estático por conta e a janela de avaliação contém os Pix pontuados, então o AUC medido é um teto, não o desempenho do ciclo anterior que o caminho quente usaria.

## 2.7 Sequências: HMM discreto, Baum–Welch e verossimilhança como anomalia

**O que é.** Um modelo oculto de Markov discreto tem estados latentes $s_t \in \{1, \dots, 3\}$ com transição $A$, emissão $B$ sobre 12 símbolos e distribuição inicial $\pi$. O algoritmo *forward* com fatores de escala $c_t$ calcula

$$\alpha_1 = \pi \odot B_{\cdot, o_1}, \qquad \alpha_t = (\alpha_{t-1} A) \odot B_{\cdot, o_t}, \qquad \log P(o_{1:T}) = \sum_t \log c_t,$$

e o Baum–Welch (EM) estima $\pi, A, B$ maximizando essa verossimilhança. Cada Pix do pagador vira um símbolo $= 4 \cdot$ faixa $+ 2 \cdot$ destino novo $+$ noite, em que a faixa (baixa, média, alta) compara o valor à mediana do próprio pagador. O score de anomalia é a CDF empírica da log-verossimilhança média negativa dos últimos Pix, em $[0, 1]$ (a `seq_anomaly_likelihood` da pesquisa, que cita Lucas et al. [9]).

**Por que serve aqui.** Árvores são rápidas, mas cegas à ordem dos eventos; o HMM resume a dinâmica temporal em um número que uma árvore pode consumir.

**Limitação.** Medido: o payload do Pix traz pouca sequência. No simulador nosso, o AUC cai de 0,652 (com o Pix atual) para 0,509 (só o que o caminho quente vê), praticamente aleatório (ADR 0026). O sinal de sequência só vale com eventos de sessão (login, troca de limite, cadastro de chave) que o enunciado não fornece. Por isso o HMM não foi avaliado no PixSim.

## 2.8 Regressão logística, calibração de Platt, *gradient boosting* e Isolation Forest

**Regressão logística e Platt.** Sobre características padronizadas $\tilde{x}_j = (x_j - \mu_j)/\sigma_j$, a margem é $m = \beta_0 + \sum_j \beta_j \tilde{x}_j$ e a probabilidade calibrada é $p = \sigma(A\,m + B)$, com $A, B$ ajustados em dados de validação (calibração de Platt). A calibração é necessária porque o desbalanceamento (pesos de classe ou subamostragem) desloca as probabilidades: com subamostragem das negativas a uma fração $\beta$, a probabilidade corrigida é $p = \beta p_s/(\beta p_s - p_s + 1)$ [6]. O projeto usa `class_weight` balanceado e Platt na validação, não subamostragem.

**LightGBM.** Soma de árvores de decisão pequenas ajustadas por *gradient boosting*; o score é $\sigma\big(b_0 + \sum_t f_t(x)\big)$, em que cada $f_t$ devolve o valor da folha alcançada. Árvores são exportadas como listas aninhadas `[feature, limiar, esquerda, direita]` e avaliadas em Python puro; a diferença máxima contra a biblioteca em 14.202 Pix foi de $1{,}1 \times 10^{-15}$ (logreg), $1{,}1 \times 10^{-16}$ (LightGBM) e $1{,}7 \times 10^{-16}$ (Isolation Forest).

**Isolation Forest.** Não supervisionado: árvores aleatórias isolam pontos; anomalias têm caminhos curtos. O score é $s(x, n) = 2^{-\mathbb{E}[h(x)]/c(n)}$, com $c(n) = 2(\ln(n-1) + \gamma) - 2(n-1)/n$ (comprimento médio de caminho numa busca binária sem sucesso) e $\gamma = 0{,}5772\ldots$; $h(x)$ soma a profundidade ao ajuste $c(\text{folha})$ pelo tamanho da folha. Treinado só com legítimos.

**Por que servem aqui.** Mostram que o desenho comporta modelos aprendidos no caminho síncrono, com inferência de microssegundos e sem inflar a imagem da API com bibliotecas de ML.

**Limitações.** Dependem de rótulos que não existem em produção; os rótulos sintéticos criam circularidade; o Isolation Forest, treinado só com legítimos do gerador, é sensível à distribuição (seção 6.6).

## 2.9 Desbalanceamento, custo assimétrico e P@$k$

**O que é.** Com fraude rara, acurácia e erro quadrático são inúteis; o certo é otimizar custo [8]. O modelo de custo do projeto (`scripts/backtest/cost-model.json`; *os valores são hipóteses de negócio, não medidas*):

| Evento | Custo |
|---|---|
| Fraude aprovada | valor do Pix (perda direta) |
| Fraude com 2FA | 10% do valor (a vítima coagida às vezes confirma) |
| Legítimo com 2FA | R$ 2,00 (atrito e abandono) |
| Legítimo reprovado | R$ 50,00 mais 2% do valor do Pix (cliente bom bloqueado, atendimento, *churn*; mesma definição do PixSim, A3.5, assumida) |
| Fraude reprovada | zero |

*(Fonte: ADR 0030, `cost-model.json` e `calibracao.md`, "Custo do falso bloqueio". Os custos medidos antes dessa mudança usavam R$ 50 fixos.)*

Como o PixSim superamostra a fraude de propósito, cada Pix de fraude carrega um peso de importância $w$ (0,0071 no mundo A) que desfaz a superamostragem. O custo ponderado por 1.000 Pix é

$$C = 1000 \cdot \frac{\sum_{\text{legít.}} c_i + w \sum_{\text{fraude}} c_j}{N_{\text{legít.}} + w\, N_{\text{fraude}}}.$$

**P@$k$.** A capacidade de uma mesa de analistas é fixa; a pergunta é a precisão nos $k$ Pix mais suspeitos do dia, com $k \in \{5, 10, 25, 50\}$ e média diária. A precisão fica inflada pela superamostragem na mesma proporção do peso, e a precisão *ponderada* dos alertas, com a taxa real de fraude, é da ordem de $1\%$.

**Limitação.** O custo absoluto depende das premissas do modelo de custo; o que se compara é a diferença entre configurações.

### 2.10 PSI e deriva; rótulos atrasados; viés de seleção; *champion/challenger* e *shadow mode*

**PSI (*Population Stability Index*).** Compara a distribuição de uma característica entre duas janelas, em $B$ intervalos (aqui 10 por quantil da amostra-base, com piso de 0,0001 por intervalo): PSI $= \sum_{i=1}^{B} (q_i - p_i) \ln(q_i/p_i)$. Leitura convencional: abaixo de 0,1 estável; 0,1 a 0,25 atenção; acima de 0,25 deriva. Serve de alarme para recalibrar ou retreinar (a pesquisa o liga a *concept drift* em Dal Pozzolo et al.).

**Rótulos atrasados.** Dal Pozzolo et al. [7] tratam do caso em que a fraude só é confirmada depois: exemplos recentes ainda não rotulados entram no treino como legítimos, o que enviesa o modelo contra o padrão mais novo. No Pix, o MED é a fonte desse atraso.

**Viés de seleção.** Um Pix que o motor reprova não liquida e portanto não gera desfecho; o que a instituição observa depois é censurado pelo próprio motor. Quanto melhor o motor, menos desfechos ele enxerga. É o problema clássico da inferência de rejeitados.

**Champion/challenger e shadow mode.** O *campeão* decide; o *desafiante* roda em paralelo, sem decidir, e é promovido se custar menos na janela de comparação. Em *shadow mode* um modelo ou regra candidata calcula e grava o que decidiria, sem alterar a resposta; isso prova que o modelo cabe no caminho síncrono (latência, dependências, serialização) sem expor o cliente a decisões guiadas por rótulo sintético (ADR 0022).

**Limitação.** Em janelas curtas e com poucos retreinos, a comparação campeão–desafiante é ruidosa (seção 6.8).

# 3 Arquitetura

## 3.1 Camadas do Base Service

O projeto parte do `bootcamp-base-api` (ADR 0001), um serviço FastAPI em camadas em que a dependência anda num sentido só: `resources` → `controllers` → (`repositories` | `rules`). Cada pasta tem um papel e uma proibição:

| Camada | Faz | Não faz |
|---|---|---|
| Middlewares | identificador da requisição, log, `INTERNAL-TOKEN` (403), sessão de banco | conhecer uma rota |
| Recursos (HTTP) | validar o corpo pelo JSON Schema (400), chamar o controller, escolher 201 ou 200 | regra, `raise` |
| Controllers | idempotência, montagem do contexto, execução das regras, decisão, gravação; único `commit`, como última linha antes do `return` | SQL direto |
| Regras | decidir se *uma* regra dispara, a partir do Pix, do contexto e dos parâmetros | banco, ambiente, relógio, ler outra regra |
| Repositórios | consultas e agregados por janela | decidir se é fraude |
| Schemas | JSON Schema com `additionalProperties: false` | regra |
| DTOs | montar `{key, status, metadata}` | serializar `id` interno ou chave estrangeira |
| Worker | jobs periódicos do *cold path*, cada um com o seu `commit` | ser chamado pela API; decidir um Pix |

Quatro regras de projeto não se negociam: teste nunca importa de `src/` nem lê o banco (R1, *black box* por HTTP); um comando sobe tudo numa máquina limpa (R2, `make all`); decisão `rejected` não é erro, sai com status 201 (R3, ADR 0003); tabelas são *append-only* e todo Pix recebido é gravado, inclusive os reprovados (R4); o `id` interno do banco nunca sai, a saída tem `key` UUID (R5); dinheiro é `BIGINT` em centavos, nunca ponto flutuante (R6).

## 3.2 *Hot path* × *cold path*

A pesquisa separa o que cabe no caminho síncrono do que não cabe. O projeto implementa as duas metades:

| | *Hot path* (dentro do `POST`) | *Cold path* (container `worker`) |
|---|---|---|
| Executa | 15 regras que decidem; 5 modelos em *shadow* | reputação de grafo por SQL, GraphSAGE e HMM |
| Cadência | por requisição | a cada 30 s (`WORKER_INTERVAL_SECONDS`) |
| Orçamento de tempo | milissegundos | segundos |
| Entrega ao *hot path* | | scores gravados em `account_risk_score` e `payer_sequence_score` (*append-only*) |
| Se o score falta ou está velho (> 120 min) | | a regra de grafo fica muda; nada quebra |

O *hot path* só **lê** o score pronto. O relógio do worker é o maior `transaction_date` da base, coerente com o relógio das regras (ADR 0007), e um ciclo é pulado se nada mudou. Os modelos aprendidos do worker dependem de `numpy`, que só existe no alvo `worker` do Dockerfile; a imagem da API não ganhou nenhuma biblioteca de ML (ADR 0025 e 0026).

## 3.3 Diagramas C4

Os diagramas abaixo (PlantUML em `docs/02-arquitetura/diagramas/`) mostram o sistema em quatro níveis.

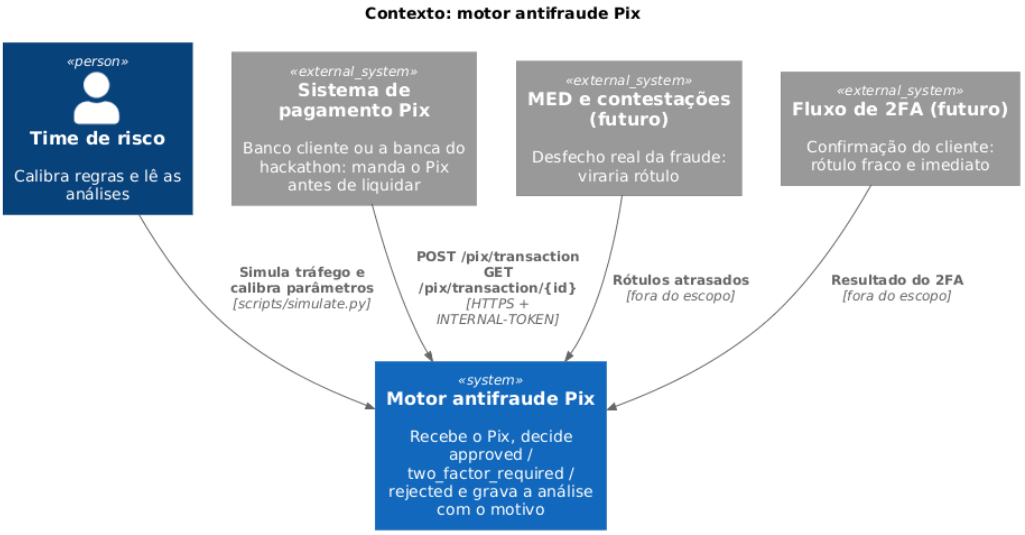



Figura 1: Contexto: quem fala com o motor (C4, nível 1).

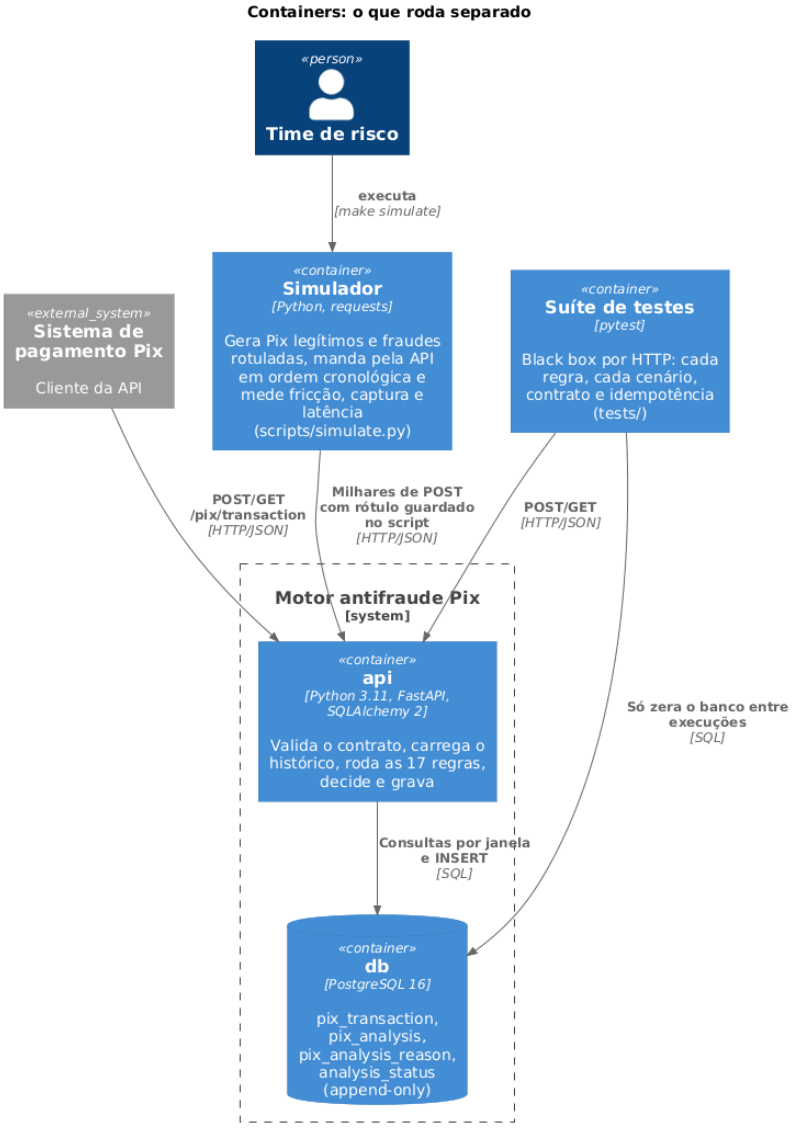



Figura 2: Containers: o que roda separado (C4, nível 2).

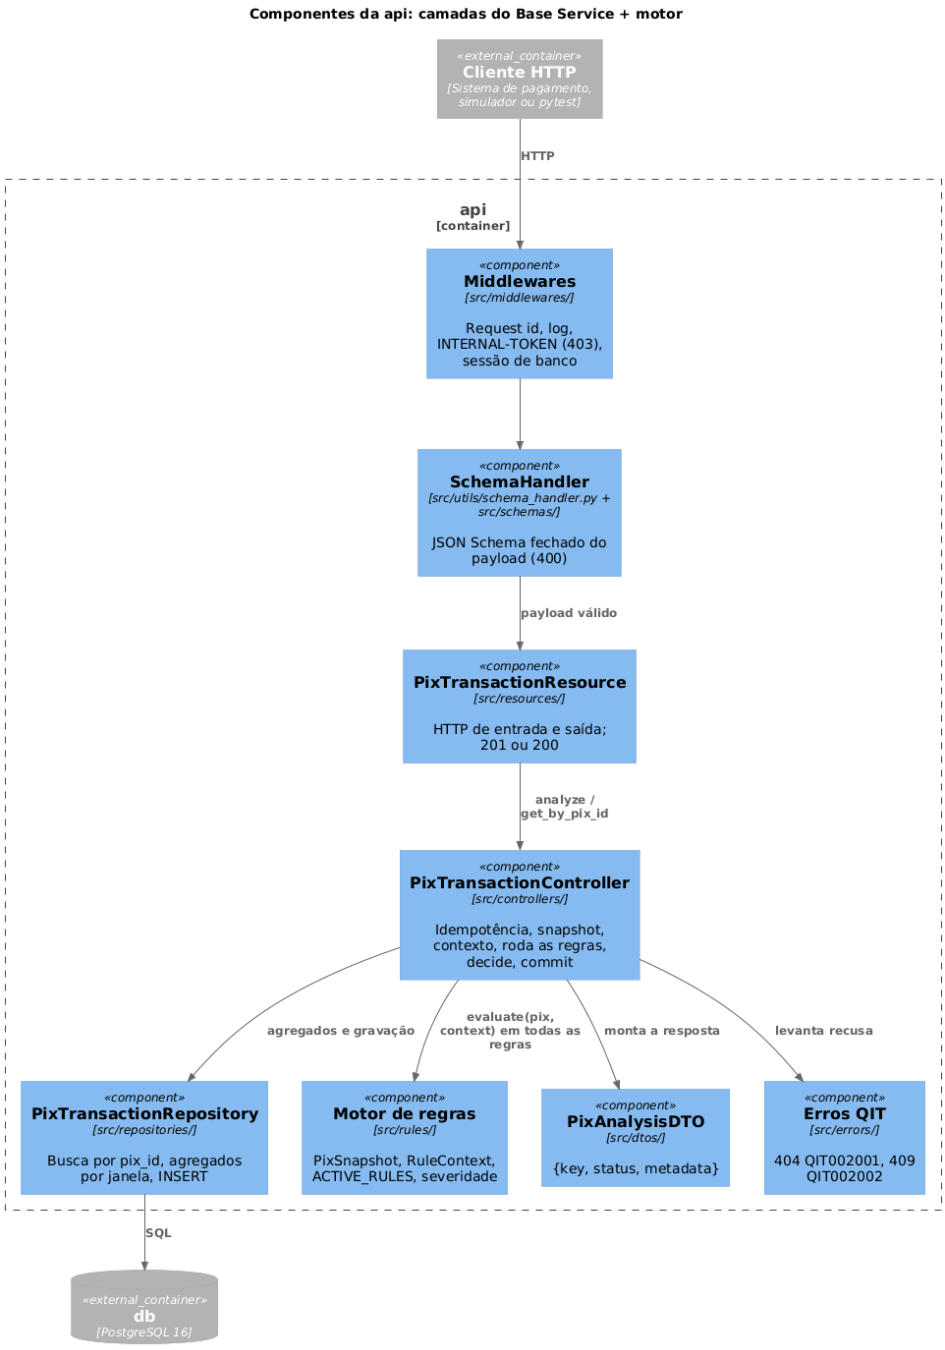



Figura 3: Componentes da API: camadas do Base Service mais o motor (C4, nível 3).

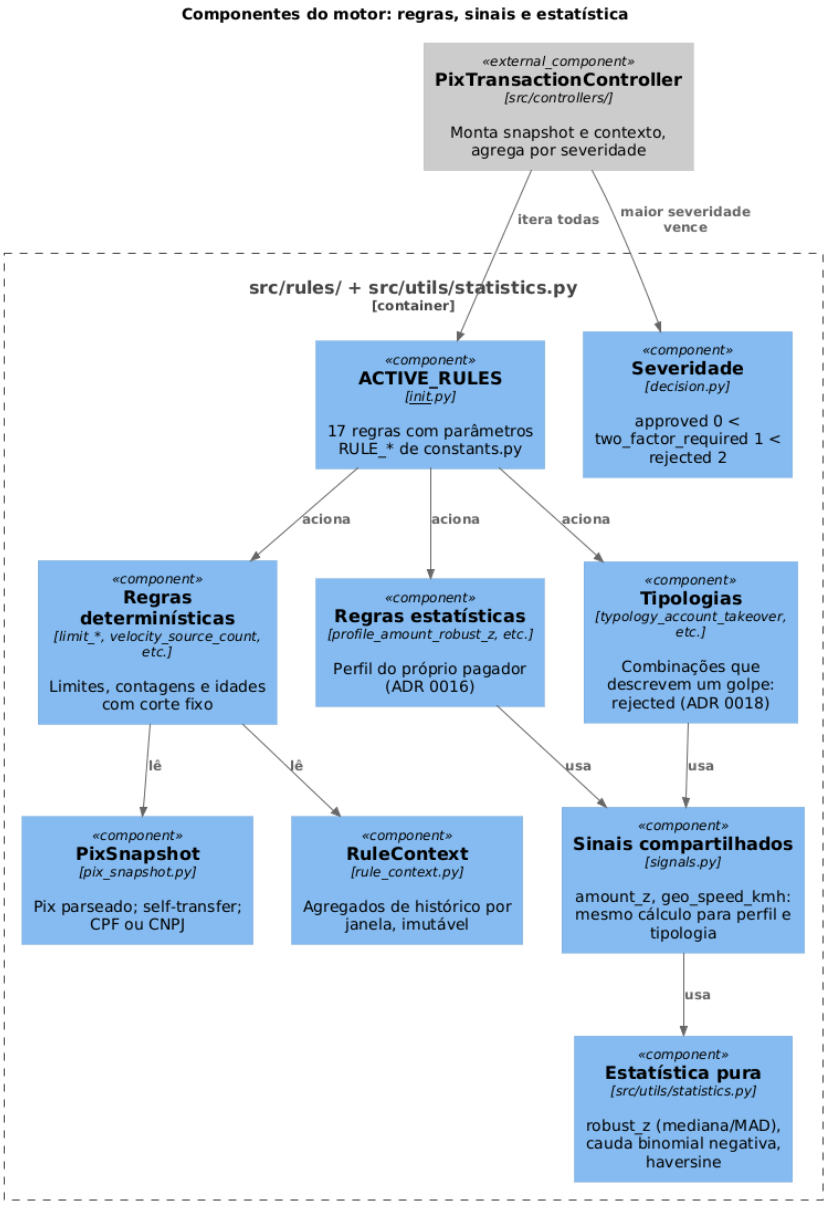



Figura 4: Componentes do motor: regras, sinais e estatística (C4, nível 3).

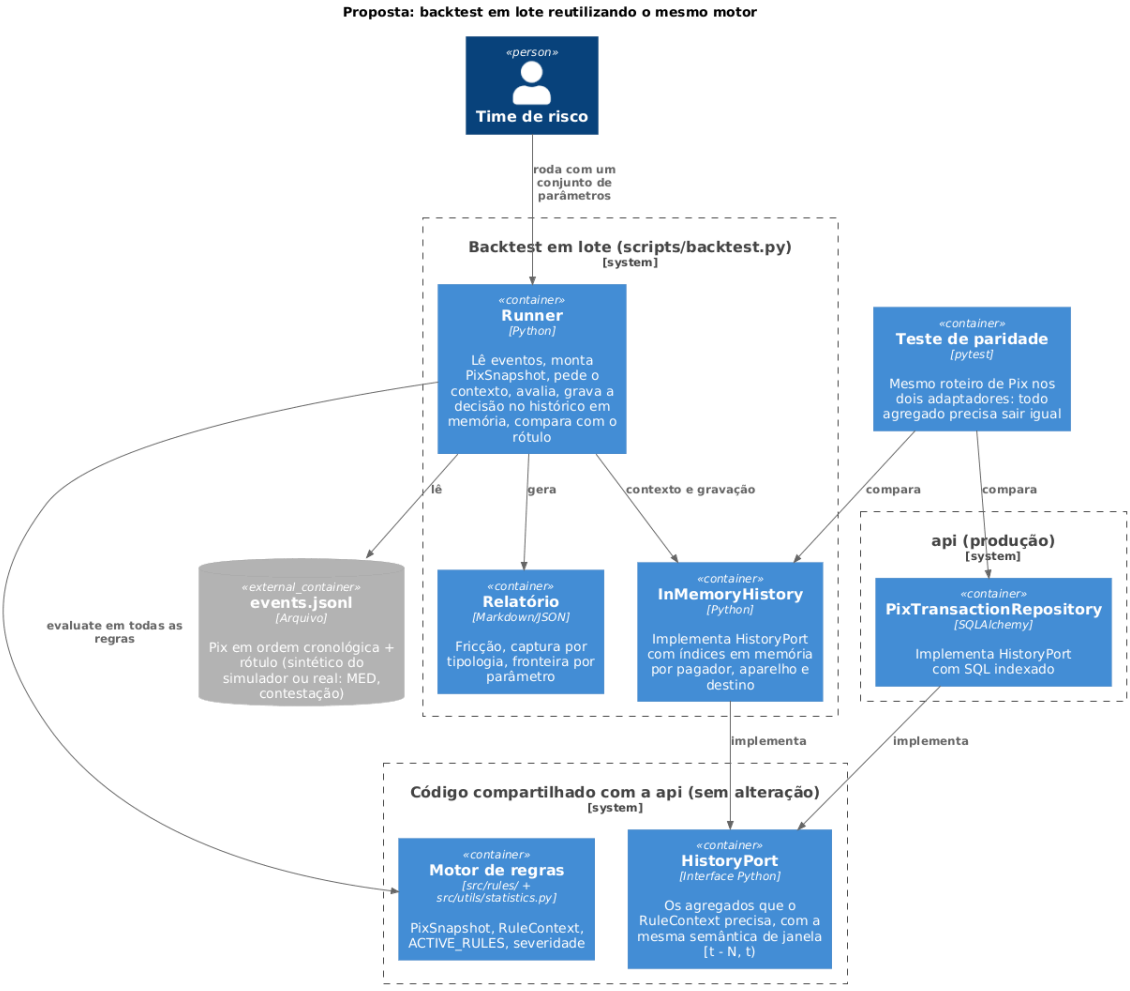



Figura 5: Backtest em lote e treino, que reutilizam o mesmo motor (visão offline).

## 3.4 Contrato da API

| Rota | Faz | Sucesso | Recusas |
|---|---|---|---|
| `POST /pix/transaction` | analisa e grava um Pix | 201 `{key, status, metadata}`; 200 se o `id` já foi analisado com o mesmo corpo | 400 `QIT000001` (corpo torto); 409 `QIT002002` (mesmo `id`, corpo diferente) |
| `GET /pix/transaction/{id}` | devolve a análise gravada, sem recalcular | 200 | 404 `QIT002001` |
| `GET /`, `GET /health_check` | identificação e saúde | 200, 204 | |

Toda rota, exceto `/` e `/health_check`, exige o cabeçalho `INTERNAL-TOKEN` (403 `QIT000002`). A saída é exatamente `{key, status, metadata}`. O `metadata` (livre no enunciado) traz:

| Campo | Conteúdo |
|---|---|
| `reasons` | um item por regra disparada (`rule`, `decision`, `reason` em português), do mais severo ao menos severo; vazia em `approved` |
| `signals` | por regra disparada, os números que ela usou (idade da conta, contagem, z, km/h, …) |
| `features` | vetor de características do Pix (33 campos, nada identificável), fonte das características de treino |
| `shadow` | o que cada regra ou modelo em sombra *decidiria* (`rule`, `would_decide`, `reason`, `signals`) |
| `rule_set_version` | versão do conjunto de regras (ADR 0021), hoje `2026.10.18-pixsim-2` |

A idempotência usa o `id` do Pix como chave natural, com `UNIQUE` no banco; a corrida entre dois `POST` iguais é resolvida pelo banco (ADR 0012). Os schemas de entrada ficam em JSON Schema (ADR 0013).

## 3.5 Modelo de dados

Quatro tabelas do histórico, todas *append-only* (R4), mais duas do *cold path*:

| Tabela | Papel | Detalhes |
|---|---|---|
| `analysis_status` | `approved` (0), `two_factor_required` (1), `rejected` (2) | a coluna `severity` faz de "o mais severo vence" um `ORDER BY` |
| `pix_transaction` | o fato: o Pix recebido | colunas tipadas (valor em `BIGINT` centavos, `TIMESTAMPTZ` com fuso, `INET`) mais `payload JSONB` para reprocessar e comparar corpo na idempotência; `pix_id UNIQUE` |
| `pix_analysis` | a opinião: decisão, `metadata`, `rule_set_version` | `analysis_key` é a `key` pública; separada do fato porque têm ciclos diferentes |
| `pix_analysis_reason` | uma linha por regra disparada | calibrar uma regra é contar disparos com SQL, sem abrir JSON |
| `account_risk_score` | score de reputação por conta (`graph_sql`, `graphsage`) | gravado pelo worker, com as contribuições de cada característica |
| `payer_sequence_score` | score de anomalia de sequência (HMM) | gravado pelo worker |

Índices por janela servem cada agregado como *range scan*: `(documento do pagador, data)`, `(aparelho, data)`, `(documento do destino, data)` e `(pagador, destino)`. Em medição (300 mil Pix em 30 dias), a consulta de pares do descartado grupo de pares levou 8,7 ms com o índice por data e 371 ms sem ele (*fonte: `validacao-pixsim.md`, "Peer group"*), o que confirma a escolha de indexar toda janela.

# 4 Implementação

## 4.1 O motor: *snapshot*, contexto, `HistoryPort` e decisão

O motor foi extraído do controller para poder rodar fora da API sem criar uma segunda versão das regras (ADR 0023). As peças, por responsabilidade:

| Peça | Responsabilidade |
|---|---|
| `PixSnapshot` | o Pix já interpretado (datas com fuso, `is_self_transfer`, `is_legal_entity_source`) |
| `RuleContext` | dataclass imutável com os agregados de histórico relativos a $t$ = `transaction_date` |
| `HistoryPort` | interface (Protocol) com os agregados de que o contexto precisa; cada método exclui o próprio Pix e olha só antes de $t$ |
| `build_context(snapshot, history)` | monta o contexto chamando o `HistoryPort` |
| `evaluate(snapshot, context, rules)` | roda *todas* as regras, ordena os disparos por severidade e devolve a decisão e o vetor de características |
| `metadata_from(resultado)` | monta `reasons`, `signals`, `features`, `shadow` e `rule_set_version` |
| Regra (`BaseRule`) | `code`, `family`, `evaluate(pix, context) -> RuleResult \| None`; pura: sem banco, ambiente nem relógio |

Dois adaptadores implementam o `HistoryPort`: o repositório SQL, na API, e um histórico em memória, no backtest. O agregado novo entra no *port*, nos dois adaptadores e no vetor de características, e a paridade acusa se faltar um lado.

**Janelas.** São $[t-N, t)$, com $t$ o `transaction_date` do próprio Pix, nunca `datetime.now()` (ADR 0007): é o que torna a decisão reprodutível e o backtest idêntico à API. Tentativas contam todos os status; somas e "conhecido" ignoram os reprovados, porque o dinheiro que não saiu não é exposição (ADR 0021).

**Decisão por severidade.** Todas as regras rodam, sem curto-circuito; cada uma devolve nada, `two_factor_required` ou `rejected`; a decisão final é a de maior severidade, e sem disparo é `approved` (ADR 0006). A ordem das regras não muda a decisão, só a ordem dos motivos (severidade e depois a ordem de `ACTIVE_RULES`). O contexto é montado uma única vez por Pix; no `POST`, o controller faz idempotência, chama o motor, grava Pix, análise e motivos e dá o `commit` na última linha.

**Parâmetros.** Todo parâmetro de regra é uma constante `RULE_*` em `src/constants.py`, lida do ambiente (ADR 0008); não há número mágico em regra. Mudar um parâmetro exige evidência do pipeline de calibração, registro do porquê e novo `RULE_SET_VERSION`.

**Regras em sombra.** `BaseRule.shadow = True` faz o motor rodar a regra e mandar o resultado só para `metadata.shadow`; nunca afeta `status`, `reasons` nem `pix_analysis_reason` (ADR 0022). Promover é trocar um atributo, registrar e mudar a versão.

## 4.2 Catálogo de regras, parâmetros e justificativas

> **Nota.** O motor tem **15 regras que decidem**, na versão `2026.10.18-pixsim-2` de `src/constants.py`. A coluna "Justificativa" resume `docs/05-motor/regras.md`, que separa a fonte regulatória (BCB, conferida no normativo), a literatura e a evidência medida no PixSim; o que não foi verificado está marcado. A contribuição medida de cada regra no PixSim está na seção 6.12 (ablação). Os parâmetros marcados com ($\star$) foram ajustados no PixSim pelo custo ponderado (seção 6.5).

As janelas são relativas ao instante da transação. "R$" abaixo é valor em reais; no código são centavos inteiros.

### 4.2.1 Limite: "passou do teto?"

| Regra | Lógica | Parâmetros | Decisão | Justificativa |
|---|---|---|---|---|
| LIMIT_NIGHT_AMOUNT | Pix entre 20h e 6h (hora local do payload) acima do teto; não vale para CNPJ | R$ 1.000 | 2FA | O BCB fixou R$ 1.000 como limite noturno padrão de pessoa física (Res. BCB 142/2021, hoje IN BCB 512/2024) [11]; o art. 39-B, §1º, III do Regulamento do Pix [12] cita horário e dia. Mantido por âncora regulatória, embora o PixSim prefira um corte maior. 2FA e não reprovação porque o cliente pode ter ampliado o limite |
| LIMIT_SINGLE_AMOUNT | Valor de um Pix acima do teto absoluto | R$ 50.000 (CPF), R$ 200.000 (CNPJ) | 2FA | Teto de exposição da instituição; o art. 37 do Regulamento do Pix [12] só permite limite por critério de risco e perfil, sem fixar valor. Valor do time, **não verificado** em fonte externa |

### 4.2.2 Velocity: "rápido demais?"

| Regra | Lógica | Parâmetros | Decisão | Justificativa |
|---|---|---|---|---|
| VELOCITY_SOURCE_COUNT | Tentativas do pagador em 10 min, contando as reprovadas | 2FA $\geq 5$; reprova $\geq 10$ | 2FA / reprova | Conta tomada é esvaziada em rajada; insistir depois de reprovado também conta (Pizzolato et al. [4]). Protege o pagador sem histórico. Limites do time, sem fonte externa |
| VELOCITY_DEVICE_SOURCES | Pagadores distintos no mesmo aparelho em 24 h | reprova $> 3$ | reprova | Fazenda de contas ou golpista com credenciais de vítimas; "família no mesmo celular raramente passa de 3" é premissa do time, **não verificada** |
| VELOCITY_POISSON_GAMMA | Cauda da preditiva Poisson–Gamma da rajada da última hora (seção 2.3), com $\geq 24$ h de exposição | ($\star$) cauda $< 30$ ppm; prior $\alpha = 1$, $\beta = 24$/h | 2FA | O "rápido demais" de cada um: conjugada Gamma–Poisson aplicada à comparação com o próprio histórico de Bolton & Hand [3]. Corte escolhido no PixSim |

### 4.2.3 Montante: "somou demais?"

**Nenhuma regra ativa.** A única regra da família, AMOUNT_SOURCE_DAILY_SUM (soma do pagador em 24 h), foi descartada pela ablação (seção 4.2.7). O teto por Pix (LIMIT_SINGLE_AMOUNT) e o z robusto (PROFILE_AMOUNT_ROBUST_Z) cobrem parte da pergunta. A soma em 24 h continua no vetor de características, porque os modelos em *shadow* a leem.

### 4.2.4 Perfil: "está no padrão do cliente?"

| Regra | Lógica | Parâmetros | Decisão | Justificativa |
|---|---|---|---|---|
| PROFILE_NEW_DEVICE | Pagador com histórico, aparelho nunca visto, valor alto | ($\star$) a partir de R$ 200 | 2FA | Troca de aparelho é o primeiro passo da credencial comprometida e do acesso remoto (Pizzolato et al. [4]); desvio do comportamento do próprio titular (Bolton & Hand [3]). O piso evita fricção no cafezinho |
| PROFILE_NEW_SOURCE_ACCOUNT | Conta de origem com menos de 7 dias e valor alto | $< 7$ dias e $>$ R$ 2.000 | 2FA | Conta aberta com identidade falsa costuma ser usada logo; o art. 39-B do Regulamento do Pix [12] cita a idade da conta, mas trata do PSP do *recebedor*; o uso para a conta de origem é analogia |

| Regra | Lógica | Parâmetros | Decisão | Justificativa |
|---|---|---|---|---|
| PROFILE_AMOUNT_ROBUST_Z | z robusto de ln(valor) sobre 30 dias do pagador (seção 2.2), $\geq 5$ Pix | ($\star$) $z > 4{,}5$; piso de escala 25% | 2FA | Escore z modificado com mediana e MAD (Iglewicz & Hoaglin [14], corte de 3,5 sob normalidade) sobre o perfil do titular (Bolton & Hand [3]); 4,5 em vez de 3,5 por calibração no PixSim |
| PROFILE_GEO_VELOCITY | Distância ao último Pix com GPS dividida pelo tempo decorrido (seção 2.4) | $> 50$ km e $> 900$ km/h | 2FA | Viagem impossível: sessão em outro aparelho ou localização falsa; 900 km/h (avião comercial) é convenção do time, **não verificada** |

### 4.2.5 Contraparte: "quem recebe é confiável?"

| Regra | Lógica | Parâmetros | Decisão | Justificativa |
|---|---|---|---|---|
| COUNTERPARTY_NEW_ACCOUNT | Idade da conta de destino; autotransferência não conta | 2FA $< 30$ dias; reprova $< 3$ dias e $>$ R$ 1.000 | 2FA / reprova | Contas laranja são abertas para receber o golpe e esvaziadas em dias; com vítima coagida só o destino denuncia. O art. 39-B, §1º, II do Regulamento do Pix [12] torna o tempo desde a abertura da conta do recebedor fator obrigatório da avaliação; os cortes são do time |
| COUNTERPARTY_FAN_IN | Pagadores distintos para o mesmo destino em 1 h | reprova $> 10$ | reprova | Conta de passagem recebendo de muitas vítimas ao mesmo tempo (funil, da pesquisa [2]); limiar do time, sem fonte externa |
| COUNTERPARTY_FIRST_TIME_HIGH | Primeiro Pix (não reprovado) do pagador para esse destino, valor alto | ($\star$) $>$ R$ 1.000 | 2FA | Falso parente e falso boleto vão para destino novo; o aluguel vai sempre ao mesmo. O art. 39-B, §1º, IV do Regulamento do Pix [12] cita a recorrência entre pagador e recebedor. É a regra de maior efeito no PixSim |
| COUNTERPARTY_GRAPH_RISK | Score de reputação do destino calculado pelo worker (seção 2.6), com até 120 min | 2FA $\geq 0{,}6$; reprova $\geq 0{,}9$ | 2FA / reprova | Conta laranja é padrão de rede; o motivo cita as duas características que mais pesaram. Cortes do time |

### 4.2.6 Tipologia: combinações que descrevem um golpe

| Regra | Lógica | Parâmetros | Decisão | Justificativa |
|---|---|---|---|---|
| TYPOLOGY_ACCOUNT_TAKEOVER | Pagador com histórico, aparelho novo e (viagem impossível ou $z > 3{,}0$) | $z > 3{,}0$ | reprova | Tomada de conta (Pizzolato et al. [4]): cada sinal sozinho pede 2FA; juntos o risco é claro (ADR 0018) |
| TYPOLOGY_MULE | Destino com $< 30$ dias e $\geq 5$ pagadores distintos em 1 h | 5 pagadores | reprova | Conta laranja: combina a idade da conta do recebedor (art. 39-B, §1º, II [12]) com o funil; barra no 5.º pagador, antes do fan-in genérico (11.º) |

### 4.2.7 Regras descartadas

Três regras saíram do motor na versão `2026.10.18-pixsim-2` (ADR 0033). O critério: uma regra fica se tiver valor por pelo menos um caminho: (1) **contribui no PixSim** (ablação positiva); (2) tem **âncora regulatória verificada** no BCB, mesmo com o PixSim preferindo outra coisa; ou (3) **cobre um sinal que**

**o PixSim não gera** (geolocalização, rajada, fazenda de aparelhos, funil, grafo do worker): não dispara lá, logo custa zero ali, e cobre um golpe que o gerador não tem. Sai a regra com ablação negativa e nenhum dos três caminhos.

| Regra descartada | Família | Ablação no mundo B (R$ por 1.000 Pix) | Por que sai |
|---|---|---|---|
| `TYPOLOGY_SPLITTING` | tipologia | $-$25,99 | Sem fonte regulatória nem acadêmica para os números; o PixSim não tem fracionamento, então a regra só reprovava legítimos |
| `COUNTERPARTY_FLAGGED` | contraparte | $-$11,76 | Só análoga ao art. 39-B, §1º, I (usa as nossas reprovações, não notificações de infração do DICT); 2FA em 0,72% dos legítimos com *lift* de 1,8x |
| `AMOUNT_SOURCE_DAILY_SUM` | montante | $-$8,69 | Nenhum normativo conferido fixa soma diária de Pix; custo em platô entre R$ 30 mil e R$ 60 mil |

*(Ablação com as 18 regras, mundo B, falso bloqueio a R$ 50 + 2%.)* Para não transformar o mundo B em mundo de ajuste, o descarte foi confirmado no mundo A, que escolhe parâmetros:

| Mundo | Custo com 18 regras | Custo com 15 regras | Pix de vítima barrados | 2FA em legítimos | Reprovação em legítimos |
|---|---|---|---|---|---|
| A (escolhe) | R$ 132,13 | R$ 109,61 | 51,7% → 50,7% | 3,81% → 2,97% | 0,012% → 0,000% |
| B (confirma) | R$ 153,51 | R$ 118,82 | 51,8% → 51,1% | 4,13% → 3,09% | 0,03% → 0,002% |

Cada uma, desligada sozinha no mundo A, também baixa o custo (`TYPOLOGY_SPLITTING` R$ 115,69; `COUNTERPARTY_FLAGGED` R$ 122,27; `AMOUNT_SOURCE_DAILY_SUM` R$ 125,93). A trava do CI no nosso simulador continua passando (6,6% de 2FA em legítimos, nenhuma reprovação, 100% das sequências de fraude barradas; o fracionamento passa a ser barrado por 2FA em vez de reprovação). Ficam, mesmo com ablação negativa: `COUNTERPARTY_NEW_ACCOUNT` e `TYPOLOGY_MULE` (art. 39-B, §1º, II), `LIMIT_NIGHT_AMOUNT` (Res. BCB 142/2021) e `PROFILE_AMOUNT_ROBUST_Z` (Iglewicz & Hoaglin [14]). As características que as três liam continuam no contexto, porque os modelos em *shadow* as usam; o código e os testes delas estão no histórico do Git até o commit `0bb5df8`.

**Ideias que não viraram regra.** Horário atípico por conta (a pesquisa indica que golpes de engenharia social acontecem em horário comercial, então um corte fixo não ajuda); distância entre `transaction_date` e o recebimento (depende de saber a hora real da chegada); IP compartilhado por muitos pagadores (sinal fraco, por NAT de operadora móvel); teste de Benford por conta (evidência fraca na pesquisa); grupo de pares (`PROFILE_PEER_AMOUNT`, implementado, medido e descartado; seção 6.9).

*(Fonte: `docs/05-motor/regras.md`, ADR 0033, `validacao-pixsim.md`.)*

## 4.3 Modelos servidos em Python puro

Treino fora da API (`scikit-learn`, `lightgbm` e `numpy` só em dev); exportação para JSON versionado; inferência em `math` puro dentro da API (ADR 0024):

| Modelo | Treino | Arquivo | Inferência |
|---|---|---|---|
| Regressão logística + Platt | `class_weight` balanceado | pesos, médias, desvios, $A$ e $B$ de Platt | margem padronizada $\rightarrow$ $\sigma(Am + B)$ |
| LightGBM | 100 árvores, 15 folhas, `scale_pos_weight` | árvores como listas aninhadas, `base_score` | soma das folhas $\rightarrow \sigma$ |
| Isolation Forest | só legítimos | árvores, tamanho das folhas, `n_samples` | comprimento médio de caminho |

Os três são regras em sombra (`MODEL_LOGREG`, `MODEL_LIGHTGBM`, `MODEL_IFOREST`); os arquivos são lidos uma vez, e se um faltar a regra não é registrada e a API sobe. Verificou-se (`make model-parity`) a equivalência com as bibliotecas sobre 14.202 Pix: diferença máxima de $1{,}1 \times 10^{-15}$. O custo de latência dos três modelos juntos foi de 149 $\mu$s por Pix no backtest (ADR 0024, medido no simulador nosso). Cada arquivo carrega `trained_on` com a origem (SHA do PixSim e semente).

## 4.4 O worker (*cold path*)

O container `worker` usa a mesma imagem de base e o mesmo código da API (`python -m worker`) e roda três jobs a cada ciclo, sobre os destinos que receberam Pix nas últimas 72 h:

1. **Reputação de grafo (`graph_sql`).** Características em SQL (funil, dispersão, dois saltos, valor, idade da conta) e o escore logístico de pesos fixos da seção 2.6; grava score e contribuições.
2. **GraphSAGE.** Monta o subgrafo da janela por SQL, amostra até 10 vizinhos por nó, executa o *forward* em `numpy` e grava o score.
3. **HMM.** Reconstrói a sequência de símbolos de cada pagador (30 dias de histórico), calcula a anomalia pela verossimilhança e grava o score.

Ciclo medido no simulador nosso: 0,31 s para os três jobs (619 destinos, 179 pagadores); a imagem do worker tem 546 MB, contra 404 MB da API. Os testes de integração do worker rodam um ciclo explícito (`docker compose run --rm worker python -m worker --once`), com o worker parado durante a suíte, como processo externo, sem importar `src/`.

## 4.5 Backtest em lote e paridade

O backtest roda o **mesmo** motor sobre um arquivo de eventos, sem HTTP e sem banco, usando o histórico em memória: 2.506 Pix/s sobre os 254.795 Pix do PixSim (101,7 s). Como o histórico em memória é uma segunda implementação dos agregados, existe o risco de *training–serving skew*; a defesa é a **paridade**: o mesmo arquivo de eventos passa pela API e pelo backtest, e status, regras disparadas e o vetor inteiro de características precisam ser idênticos Pix a Pix (`make parity`). Como o vetor cobre todos os agregados, a igualdade prova que os dois adaptadores contam igual sem que nenhum teste importe `src/` (R1). No PixSim a paridade foi verificada em 500 Pix (cerca de 40 de fraude, janela na virada do burn-in): **0 divergências** (`make pixsim-parity`; *fonte: `validacao-pixsim.md`, "Limitações"*). Fora dessa amostra o backtest em memória não foi comparado com a API.

No backtest os scores do *cold path* são `None` (o histórico em memória não executa o worker), o que mantém a paridade exata e significa que as regras de grafo, GraphSAGE e HMM não foram exercitadas na validação do PixSim em lote.

## 4.6 Mapa do código

Esta seção concentra os caminhos de arquivo; o restante do relatório descreve módulos por responsabilidade. Atualize apenas esta tabela se a estrutura mudar (a mesma tabela, mais detalhada, está em `docs/02-arquitetura/camadas.md`, "Onde fica o quê", e em `scripts/README.md`).

| Responsabilidade | Onde |
|---|---|
| Aplicação, middlewares, erros | `src/app.py`, `src/middlewares/`, `src/errors/` |
| Rota HTTP, schema, DTO | `src/resources/pix_transaction.py`, `src/schemas/post_pix_transaction.json`, `src/dtos/` |
| Controller (idempotência, gravação, `commit`) | `src/controllers/pix_transaction_controller.py` |
| Consultas e agregados SQL | `src/repositories/` (Pix, grafo, GraphSAGE, sequência) |
| Tabelas | `database/database.sql`, `src/models/` |
| Parâmetros `RULE_*` e `RULE_SET_VERSION` | `src/constants.py` |
| Lista ativa (`build_rules`, `ACTIVE_RULES`) | `src/rules/__init__.py`; a ordem da lista desempata motivos de mesma severidade |
| Motor (`engine.py`), `BaseRule`, decisão, `PixSnapshot`, `RuleContext`, `HistoryPort`, características, sinais compartilhados | `src/rules/core/` |
| Regras (uma classe por arquivo, `<familia>_<sinal>_rule.py`) | `src/rules/limit/`, `velocity/`, `profile/`, `counterparty/`, `typology/` |
| Estatística pura (z robusto, cauda Poisson–Gamma, haversine) | `src/utils/statistics.py` (fica em `utils/` porque os scripts de análise também a usam) |
| Modelos servidos em Python puro | `src/rules/models/` (`logreg`, `gbdt`, `iforest`, regras em *shadow*) e `src/rules/models/artifacts/*.json` |
| *Cold path* | `src/worker/__main__.py`; jobs em `src/worker/jobs/` (grafo, GraphSAGE, HMM); modelos em `src/worker/models/` (`scoring.py`, `graphsage.py`, `hmm.py`, `artifacts/*.json`) |
| Nosso simulador (fixture de CI) | `scripts/fixture/` (`simulate.py`, `replay.py`, `report.py`, `api_client.py`) |
| Backtest, histórico em memória, paridade, custo | `scripts/backtest/` (`backtest.py`, `in_memory_history.py`, `parity.py`, `costs.py`, `cost-model.json`) |
| Calibração, trava do CI, ablação | `scripts/calibration/` (`calibrate.py`, `calibration-grid-pixsim.json`, `calibration-gate.json`, `rule_ablation.py`) |
| PixSim | `scripts/pixsim/` (`pixsim_setup.sh`, `pixsim_export.py`, `pixsim_adapter.py`, `pixsim_report.py`, `pixsim_scores.py`, `pixsim_waterfall.py`) |
| Treino e avaliação de modelos, rótulos atrasados, ruído do escorer | `scripts/models/` (`train_models.py`, `train_graphsage.py`, `train_hmm.py`, `export_features.py`, `model_eval.py`, `check_model_parity.py`, `delayed_labels.py`, `scorer_noise.py`) |
| Retroalimentação pelo MED; análises estatísticas | `scripts/feedback/` (`feedback.py`, `feedback_core.py`); `scripts/analysis/analyze.py` |
| Testes *black box* (113, só por HTTP) | `tests/` |
| Orquestração | `Makefile`, `docker-compose.yml`, `Dockerfile`, `.github/workflows/ci.yml` |
| Documentação e decisões | `docs/` (ADRs em `docs/02-arquitetura/decisoes/`) |

Os scripts se importam pelo nome do módulo: cada um começa importando `scripts/_paths.py`, que põe `src/` e as pastas de `scripts/` no `sys.path`; toda saída vai para `scripts/out/`, fora do Git.

# 5 Metodologia de validação

## 5.1 Por que o nosso simulador é só *fixture* de CI

O primeiro simulador (`scripts/fixture/simulate.py`, ADR 0020) gera pagadores legítimos e injeta cinco tipologias de fraude que o próprio time desenhou (conta tomada, mula, fracionamento, golpe noturno e fazenda de contas). As regras foram escritas procurando exatamente esses padrões, logo a medição é **circular**: sobre ele, a captura de Pix de vítima chegava a cerca de 92% e metade do valor das vítimas era reprovada, enquanto no PixSim o mesmo motor barrou cerca de 36% dos Pix de vítima antes da calibração (ADR 0029; *fonte: `validacao-pixsim.md`, "O que se mantém e o que cai"*). Os modelos treinados nele também não generalizaram: o LightGBM obteve AUC 0,58 e a regressão logística 0,77 no PixSim (ADR 0031).

Decisão (ADR 0029): todo número de resultado vem do PixSim. O nosso simulador permanece porque é rápido, determinístico e roda em máquina limpa, e serve a duas coisas: os testes de paridade e a **trava de regressão** `make calibrate-check`, que roda o backtest com os padrões sobre o simulador (semente 42, 200 pagadores, 14 dias) e falha se passar de legítimos reprovados $\leq 0{,}1\%$, 2FA em legítimos $\leq 7{,}0\%$ ou menos de 100% das sequências de fraude com algum Pix barrado. A trava não é meta e não justifica nenhum parâmetro. Medido com as 15 regras: nenhuma reprovação, 6,6% de 2FA, 100% das sequências (*fonte: ADR 0033*).

## 5.2 O PixSim

O PixSim [5] é um simulador aberto (Apache-2.0) de fraude em pagamentos instantâneos, calibrado com dados abertos do Banco Central. Gera contas (pessoa física e jurídica, região, faixa etária, idade da conta), tráfego legítimo (Poisson não homogêneo por conta), quatro tipologias de fraude do lado do pagador (engenharia social, conta tomada, Pix errado e QR adulterado) e cadeias de dispersão por mulas até contas de saída, com atraso de reporte ao MED. Usamos o commit `7fdfc90013960f46df60c3ea01838e768e7a420a`. Foi usada **apenas a geração de transações**: a política de analistas, bloqueios e recuperação pelo MED do artigo não foi usada.

**Código de terceiro, tratado como não confiável.** Antes de executar foram lidos o README, as dependências e os módulos chamados; não rodamos os testes, notebooks nem instaladores dele. As dependências pinadas foram instaladas em venv próprio (Python 3.13), sem privilégio, e o gerador roda com `python -I` e limite de memória. Tudo fica em `scripts/out/pixsim/`, fora do Git.

## 5.3 Escala reduzida

| Item | Valor |
|---|---|
| Contas | 5.025 (5.000 mais 25 contas de saída do PixSim) |
| Janela avaliada | 30 dias (mundo A: semente 20260910) |
| *Burn-in* | 30 dias antes do dia 0, 122.967 Pix legítimos enviados ao motor como histórico e excluídos das métricas |
| Pix totais | 254.795 (125.518 legítimos avaliados) |
| Eventos de fraude | 986: 618 engenharia social, 209 conta tomada, 91 Pix errado, 68 QR adulterado |
| Pix de fraude | 6.310: 1.380 pagador→mula, 91 sementes de Pix errado, 1.771 `mule_forward`, 3.068 `cash_out` |
| Peso de importância da fraude | 0,0071 |

*(Fonte: `validacao-pixsim.md`, "Escala usada" e "Tamanho avaliado".)* O artigo roda 1,08 milhão de contas (19 GB por parte); a máquina de desenvolvimento tem cerca de 2 GB livres. O backtest lê os eventos em *streaming* (pico de memória de 2,07 GB para 0,52 GB, saída idêntica). Duas escolhas fora do `baseline.yaml` do PixSim: *burn-in* de 30 dias em vez de 90 (30 dias cobrem a maior janela do

motor) e 1.000 eventos de fraude por mês em vez de 2.000 (calibrados para 100 mil contas). A fraude é superamostrada de propósito, e os custos "ponderados" aplicam o peso de importância.

## 5.4 Adaptador: o que foi mapeado, inventado e não existe

| Campo do contrato | Origem |
|---|---|
| `amount` | valor em R$ do PixSim para centavos inteiros (`Decimal`, meio para cima, mínimo 1 centavo) |
| `transaction_date` | início fixo 2026-09-01T00:00-03:00 mais o tempo em segundos do PixSim; o *burn-in* tem tempo negativo |
| `source_account`, `destination_account` | **inventados**: agência, conta e ISPB determinísticos a partir do `account_id`; `opening_date` do PixSim deslocada para a mesma origem, preservando a idade da conta |
| `owner.document_number` | **inventado**: CPF ou CNPJ sintético com dígitos verificadores válidos, derivado do `account_id` por mapa bijetor |
| `source.device_id` | o dispositivo do PixSim |
| `source.channel` | `mobile` → `app`, `internet` → `internet_banking`; saídas da dispersão: `crypto_exit`, `cash_withdrawal`, `merchant_purchase` |
| `source.ip` | **inventado**: derivado do hash do dispositivo, faixa 198.18.0.0/15 |
| `source.geolocation` | **não existe** no PixSim: o campo opcional fica ausente e as regras e características geográficas ficam inertes |

Os 254.795 payloads gerados passam no JSON Schema do enunciado (0 inválidos). Rótulos e metadados do PixSim (`typology`, `role`, `burn_in`, `weight`, `report_delay_days`) viajam no arquivo de eventos mas **não** vão ao motor.

## 5.5 Mundos A e B; perspectiva do banco pagador

O **mundo A** (semente 20260910) serve para *escolher* parâmetros e *treinar* modelos; o **mundo B** (semente 20261017, 259.646 Pix, 986 eventos de fraude, 1.438 Pix de vítima) serve para *confirmar* e *testar*. Os dois têm a mesma escala e vêm do mesmo gerador e da mesma configuração; só muda a semente. Portanto o teste mede generalização entre *amostras* do PixSim, não entre geradores.

**Perspectiva.** O motor vê todos os Pix, mas a leitura é a do banco pagador. "Pagador→mula" (`victim_to_mule`) é a fraude contra o nosso cliente e é o que o motor deve barrar. A dispersão (`mule_forward`, `cash_out`) e a semente do Pix errado só chegariam ao motor se a mula fosse cliente do mesmo banco; entram numa visão separada e não somam na captura principal nem no objetivo da calibração.

## 5.6 Métricas

| Métrica | Definição |
|---|---|
| Fricção | parcela dos legítimos com 2FA (e reprovados) |
| Captura | parcela dos Pix de vítima fora de `approved`; e, por evento de fraude, parcela com ao menos um Pix de vítima barrado |
| Custo ponderado por 1.000 Pix | seção 2.9, com `cost-model.json` e o peso de importância |
| P@$k$ diário | precisão nos $k \in \{5, 10, 25, 50\}$ Pix mais suspeitos do dia (ranking: decisão das regras como escore, ou escore do LightGBM) |
| AUC | pontuação do modelo na fraude contra o legítimo |
| Recall e fricção no limiar | no limiar do próprio modelo, escolhido por F1 máximo no pedaço de validação |
| PSI | deriva de características entre dois conjuntos |
| Latência | por Pix, em memória e pela API |

Para modelos, "positivo" é o Pix de vítima; "legítimo" é o tráfego legítimo. A dispersão e a semente do Pix errado ficam fora do treino e da avaliação, porque misturá-las ensinaria o modelo a pontuar o comportamento da mula e não o da vítima. AUC, recall e P@$k$ são brutos (sem ponderar); custos e precisão ponderada usam o peso.

## 5.7 Avaliação nos dois sentidos

Para separar "aprendeu o PixSim" de "aprendeu o nosso gerador", os modelos são avaliados em **ambos os sentidos**: treinados no nosso simulador e testados no PixSim B, e treinados no PixSim A e testados no PixSim B (generalização entre sementes) e no nosso simulador (semente 7). O sentido inverso (PixSim A $\rightarrow$ nosso) mostra que os dois geradores ensinam sinais diferentes: nenhum modelo é "o" modelo e o PixSim não substitui o teste no nosso simulador.

## 5.8 Calibração por custo (mundo A escolhe, mundo B confirma)

O grid varre **um parâmetro por vez** a partir da linha de base (os padrões anteriores, fixados em `calibration-grid-pixsim.json`), mais a combinação dos melhores valores de cada um: 21 combinações no mundo A, ~20 passadas de 1 min. O objetivo é o menor custo ponderado por 1.000 Pix na visão do pagador; em empate, menos legítimos reprovados e depois mais sequências barradas. As metas, em ordem: (1) legítimos reprovados perto de zero; (2) custo mínimo; (3) 2FA em legítimos abaixo de 5% quando o custo empata. O script nunca altera `src/constants.py`; a escolha final e o porquê são do time (ADR 0027). Parâmetros varridos: teto diário, cauda da Poisson, corte do fracionamento, z do perfil, valor mínimo de aparelho novo, valor mínimo do primeiro Pix para um destino e limite noturno (o teto diário e o corte do fracionamento pertenciam a regras depois descartadas pela ablação, seção 4.2.7).

## 5.9 Alinhamento com a metodologia do PixSim e comparação com o artigo

Com base em `docs/metrics_definitions.md` do PixSim (SHA 7fdfc90), os pontos de contato são:

| Aspecto | PixSim | Aqui | Situação |
|---|---|---|---|
| Perspectiva e positivos | banco pagador; Pix `victim_to_mule`, dispersão à parte | os mesmos | alinhado |
| Peso da cadeia | peso de importância por evento de fraude | o mesmo peso em custos e cascata | alinhado |
| Falso bloqueio | R$ 50 + 2% do valor | R$ 50 + 2% do valor, desde esta mudança | alinhado (antes: R$ 50 fixos) |
| Escala | 1,08 milhão de contas, 90 dias de aquecimento | 5 mil contas, 30 dias | difere |
| Fraude | taxa real com pesos | superamostrada; os pesos corrigem custo, não P@$k$ | difere |
| Ações | `pass`, `alert` (fila), `block` | `approved`, `two_factor_required`, `rejected` | difere: sem fila de analistas |
| Regimes do MED de 2026, marcação no DICT | comparados | só o relógio padrão | difere |
| Scorer | GBM ajustado no aquecimento, avaliado na janela do mesmo mundo | treinado no mundo A, avaliado no B | difere: AUC não comparável |

*(Fonte: `validacao-pixsim.md`, "Alinhamento com a metodologia do PixSim".)*

O resumo do artigo cita um escorer sintético com AUC de 0,82. Esse número **não é comparável** aos nossos 0,99: o desenho da avaliação é outro (escala cheia, escorer ajustado no aquecimento e avaliado na janela seguinte do mesmo mundo, com as características do PixSim). A diferença **não** se explica por ruído: o ruído de score do PixSim só existe no seu experimento de sensibilidade S7; o escorer padrão não tem ruído

(score_noise_sigma = 0). O 0,82 serve, no máximo, como ordem de grandeza. A seção 6.14 replica o S7 sobre os nossos modelos.

## 5.10 Vazamento de dados e vieses do gerador

Um AUC de 0,99 pede a pergunta: o modelo está vendo a resposta? Checamos o vazamento de dados (*data leakage*) em quatro frentes e separamos o que é vazamento do que é viés do gerador.

**Sem vazamento de rótulo.** O adaptador só passa ao motor os campos do contrato do enunciado. Os campos do PixSim que entregariam a resposta (label, role, ring_id, is_mule, is_new_counterparty, hop_depth, sender_balance_before) ficam fora do payload. As características vêm só do histórico *anterior* ao Pix: a paridade API × backtest (seção 4.5) deu 0 divergências, o que confirma que o backtest não olha o futuro, já que a API não tem como olhar. O score de grafo nunca entra no backtest (o worker não roda lá).

**Mundos A e B independentes.** Só muda a semente, mas as populações não se repetem: só 3 das 5.025 contas têm a mesma data de abertura nos dois mundos, e as mulas com o mesmo account_id nos dois mundos são 364, contra cerca de 359 esperadas ao acaso.

**Separação no tempo.** Os modelos são ajustados nos primeiros 75% do mundo A, em ordem de transaction_date, e o limiar é escolhido nos 25% finais; o teste é no mundo B. Na retroalimentação, o desfecho do MED só chega em transaction_date + atraso de reporte, nunca antes.

**Valores "colados" não explicam o resultado.** O PixSim gera fraudes com valores logo abaixo de números redondos (R$ 999,99, R$ 1.999,99, …): são 22% das fraudes e 0% do legítimo, um atalho que o modelo poderia decorar. O LightGBM não depende dele:

| Teste (LightGBM, treino A, teste B) | AUC |
|---|---|
| Linha de base do experimento (mesma receita de treino) | 0,992 |
| Sem as fraudes de valor colado | 0,990 |
| Com ruído de $±$3% no valor, no treino e no teste | 0,993 |

O experimento retreina o LightGBM à parte, por isso a linha de base (0,992) difere do modelo instalado (0,989, seção 6.6); o que importa é a variação dentro do experimento, de no máximo 0,002.

**Vieses do gerador (não são vazamento).** O AUC alto vem de premissas do PixSim, não de um atalho no nosso pipeline:

- só o valor dá AUC de 0,937, e sem nenhuma característica de valor o modelo ainda chega a 0,943; as medianas de valor da fraude no PixSim são premissas marcadas como ASSUMED (A2.2) no próprio PixSim, não medidas;
- o PixSim limita o Pix de conta tomada à noite a R$ 1.000 (assume que o banco aplica o limite noturno), então LIMIT_NIGHT_AMOUNT não consegue disparar nessa tipologia;
- 19% dos Pix de vítima do mundo B estão em exatamente R$ 999,99 ou R$ 1.000,00, invisíveis para COUNTERPARTY_FIRST_TIME_HIGH, que pede valor acima de R$ 1.000;
- o mundo B, usado na ablação e na escolha dos modelos, deixou de ser teste puro; por isso o descarte das três regras (seção 4.2.7) foi confirmado também no mundo A.

## 5.11 O que o PixSim não gera

O PixSim não gera geolocalização, IP, fazenda de aparelhos (um aparelho por conta), rajada na conta da vítima, funil de muitas vítimas na mesma hora para a mesma mula, nem fracionamento; e o worker não roda no backtest. As regras desses sinais (PROFILE_GEO_VELOCITY, VELOCITY_SOURCE_COUNT, VELOCITY_DEVICE_SOURCES, COUNTERPARTY_FAN_IN, COUNTERPARTY_GRAPH_RISK e a parte geográfica de TYPOLOGY_ACCOUNT_TAKEOVER) nunca disparam lá: ficam pelo critério 3 da ADR 0033 (cobrem um

sinal que o PixSim não gera, com custo zero nele). A evidência delas é outra: testes pela API (um que dispara e um que não dispara, por regra) e a trava do CI no nosso simulador, que gera esses padrões. Não inventamos geolocalização no adaptador, porque mediríamos a nossa própria invenção, o mesmo erro circular da seção 5.1.

# 6 Resultados no PixSim

Todas as medidas desta seção são **métricas no PixSim**, em escala reduzida, com uma semente por mundo e sem intervalo de confiança. Salvo menção, valem para o conjunto final (`2026.10.18-pixsim-2`, 15 regras, parâmetros calibrados, falso bloqueio a R$ 50 + 2%) no mundo A. Diferenças de custo abaixo de cerca de R$ 1 por 1.000 Pix são ruído nesta escala.

## 6.1 Fricção em legítimos

| Conjunto | Legítimos | `approved` | 2FA | `rejected` |
|---|---|---|---|---|
| PixSim A | 125.518 | 97,03% | 2,97% | 0,00% |
| PixSim B | 127.683 | 96,91% | 3,09% | 0,002% |

*(Fonte: `validacao-pixsim.md`, "Fricção em legítimos" e "Contribuição de cada regra".)* A meta de 2FA abaixo de 5% foi cumprida nos dois mundos, e nenhum legítimo do mundo A é reprovado.

## 6.2 Captura por tipologia

| Tipologia | Pix de vítima | Aprovado (escapou) | 2FA | Reprovado | Eventos com ao menos um Pix barrado |
|---|---|---|---|---|---|
| Conta tomada | 323 | 22,60% | 73,07% | 4,33% | 206/209 (98,6%) |
| Engenharia social | 898 | 53,12% | 46,88% | 0,00% | 350/618 (56,6%) |
| QR adulterado | 68 | 72,06% | 27,94% | 0,00% | 19/68 (27,9%) |
| Pix errado | 91 | 90,11% | 9,89% | 0,00% | 9/91 (9,9%) |
| **Total (vítima)** | 1.380 | 49,3% | | | 584/986 (59,2%) |

*(Fonte: `validacao-pixsim.md`, "Captura por tipologia" e "Sequências e anéis"; a linha de total é derivada: 50,7% dos Pix de vítima barrados.)* Conta tomada é a tipologia mais barrada; engenharia social, Pix errado e QR adulterado escapam em boa parte porque o Pix da vítima parece um pagamento comum, dentro do perfil dela. Em valor, só 1,7% do dinheiro das vítimas é reprovado, 70,2% cai em 2FA (que a vítima coagida pode confirmar) e 28,2% passa aprovado. Na visão da dispersão (mula movendo o dinheiro), 70,9% dos eventos têm ao menos um Pix barrado em qualquer papel (699/986), e todos os 75 anéis de mulas têm ao menos um Pix barrado (75/75); a parte da dispersão só ajudaria se a mula fosse cliente do banco.

Regras que disparam em legítimos são raras: a mais frequente é `COUNTERPARTY_FIRST_TIME_HIGH` (1,2%), seguida de `COUNTERPARTY_NEW_ACCOUNT` (1,2%) e `LIMIT_NIGHT_AMOUNT` (0,6%); em Pix de vítima, `COUNTERPARTY_FIRST_TIME_HIGH` dispara em 33,0%, `PROFILE_NEW_DEVICE` em 14,9% e `VELOCITY_POISSON_GAMMA` em 6,4%. `TYPOLOGY_MULE`, `COUNTERPARTY_FAN_IN` e `COUNTERPARTY_NEW_ACCOUNT` ficam em zero em Pix de vítima: no PixSim as mulas são contas com idade comum, e as vítimas chegam à mesma mula espalhadas no tempo, não em rajada (hipótese; não medimos a distribuição temporal). *(Fonte: `validacao-pixsim.md`, "Regras que disparam" e "O que se mantém e o que cai".)*

## 6.3 Custo esperado

| Visão | Custo ponderado por 1.000 Pix | Parte fraude | Parte fricção |
|---|---|---|---|
| Visão pagador (legítimo + pagador→mula) | R$ 109,61 | R$ 50,12 | R$ 59,49 |
| Visão dispersão (legítimo + dispersão) | R$ 212,59 | R$ 153,11 | R$ 59,48 |

*(Fonte: `validacao-pixsim.md`, "Custo esperado (V1").)* O custo bruto (sem ponderar) da visão pagador é R$ 7.023,16 por 1.000 Pix, inflado pela superamostragem. A fricção responde por cerca de 54% do custo ponderado na visão pagador: com a taxa de fraude real, o atrito sobre o legítimo pesa tanto quanto a fraude que passa.

## 6.4 P@$k$ diário

| Ranking | P@5 | P@10 | P@25 | P@50 |
|---|---|---|---|---|
| Visão pagador, regras | 13,3% | 16,7% | 21,7% | 22,9% |
| Visão pagador, regras + LightGBM (dentro da amostra) | 100,0% | 98,7% | 89,1% | 70,1% |
| Visão dispersão, regras | 11,0% | 17,7% | 28,0% | 29,7% |
| Visão dispersão, regras + LightGBM (dentro da amostra) | 71,0% | 57,1% | 43,9% | 35,8% |

*(Fonte: `validacao-pixsim.md`, "P@k diário (V1").)* **Cuidados.** A fraude está superamostrada e a precisão fica inflada na proporção do peso; com a taxa real, a precisão ponderada dos alertas fica abaixo de 1% e a fila dos analistas seria quase toda de falso positivo. Além disso, a linha "regras + LightGBM" usa o LightGBM instalado, treinado no mundo A, **no próprio mundo A** (dentro da amostra); fora da amostra, no mundo B, o mesmo ranking dá P@5 de 96,7% e P@50 de 57,9% (seção 6.6).

## 6.5 Calibração: efeito de cada parâmetro e configuração final

A calibração foi feita **antes** do descarte das três regras: grid no mundo A com as 18 regras de então e falso bloqueio a R$ 50 fixos (*fonte:* `calibracao.md`). Efeito de cada parâmetro que continua no motor, sozinho, sobre a linha de base (custo R$ 143,58 por 1.000 Pix; 3,50% de 2FA em legítimos; 36,1% dos Pix de vítima barrados; 383 de 986 eventos barrados):

| Mudança | Custo R$/1.000 | 2FA legítimos | Pix de vítima barrados | Eventos barrados |
|---|---|---|---|---|
| Primeiro Pix para destino: R$ 3.000 → **R$ 1.000** | **135,72** | 4,16% | 52,2% | 577 |
| Limite noturno R$ 1.000 → R$ 2.000 (não aplicado) | 139,01 | 3,18% | 34,4% | 365 |
| Cauda Poisson 100 → **30** ppm | 142,30 | 3,30% | 33,3% | 368 |
| z do perfil 3,5 → **4,5** | 142,33 | 3,35% | 35,2% | 376 |
| Aparelho novo R$ 500 → **R$ 200** | 142,91 | 3,50% | 38,8% | 413 |
| Cauda Poisson 100 → 1.000 ppm | 166,48 | 5,03% | 42,0% | 426 |
| Limite noturno R$ 1.000 → R$ 500 | 152,77 | 4,10% | 40,9% | 434 |

O valor mínimo do primeiro Pix para um destino é o parâmetro de maior efeito no custo. O grid também varria o teto diário e o corte do fracionamento, que saíram do código com as suas regras (seção 4.2.7); as linhas deles ficam registradas em `calibracao.md`.

**Configuração final.** Ficam no motor quatro parâmetros calibrados: primeiro Pix para destino novo a partir de R$ 1.000, aparelho novo a partir de R$ 200, cauda da Poisson em 30 ppm e z do perfil acima de 4,5. O efeito de cada etapa, com o mesmo modelo de custo (R$ 50 + 2%):

| Mundo | Etapa | Custo R$/1.000 Pix | Pix de vítima barrados | 2FA em legítimos |
|---|---|---|---|---|
| B | 15 regras, parâmetros anteriores à calibração | 127,26 | 37,4% | |
| B | 18 regras, parâmetros calibrados | 153,51 | 51,8% | 4,13% |

| Mundo | Etapa | Custo R$/1.000 Pix | Pix de vítima barrados | 2FA em legítimos |
|---|---|---|---|---|
| B | **15 regras, parâmetros calibrados (final)** | **118,82** | 51,1% | 3,09% |
| A | 18 regras, parâmetros calibrados | 132,13 | 51,7% | 3,81% |
| A | **15 regras, parâmetros calibrados (final)** | **109,61** | 50,7% | 2,97% |

*(Fonte: `validacao-pixsim.md`, "Contribuição de cada regra"; ADR 0033.)* No conjunto final, a calibração tira R$ 8,44 por 1.000 Pix no mundo B e leva os Pix de vítima barrados de 37,4% para 51,1%. Na escolha original (18 regras, R$ 50 fixos) o ganho foi de R$ 11,92 no mundo A e R$ 8,36 no B; o ganho menor em B é a melhor estimativa de quanto a escolha é específica de um mundo.

**Limite noturno mantido por âncora regulatória.** O grid preferia R$ 2.000 para `LIMIT_NIGHT_AMOUNT`, mas o parâmetro ficou em **R$ 1.000**, o limite noturno padrão de pessoa física do BCB (Res. 142/2021) [11]: subir o corte pararia de pedir 2FA abaixo do teto que o regulador associa ao risco de sequestro relâmpago. Com o conjunto final, R$ 2.000 custaria R$ 114,02 no mundo B contra R$ 118,82 (+R$ 4,80 por 1.000 Pix pela âncora). O parâmetro é `pinned` no grid: medido, nunca escolhido.

**Sensibilidade (mundo A).** A análise 4 de `analises.md` varre a cauda da Poisson e o z do perfil com os demais parâmetros nos padrões atuais. `RULE_POISSON_TAIL_PPM` tem o maior efeito (R$ 24,51 de amplitude de custo; 1,81 p.p. de fricção; 9,57 p.p. de fraude barrada) e `RULE_PROFILE_Z_2FA_TENTHS` o menor (R$ 11,27; 1,00 e 4,13 p.p.). Onde a fraude barrada não muda com a fricção, o limiar está num platô e a escolha é por custo de falso positivo; onde as duas sobem juntas, há troca real. A sensibilidade no mundo B está na seção 6.12.

## 6.6 Modelos em *shadow*

Treino no mundo A, teste no mundo B e no nosso simulador (semente 7), com as características do conjunto `2026.10.18-pixsim-2`. Hiperparâmetros fixos de `train_models.py`; ajuste nos primeiros 75% do mundo A no tempo (95.173 linhas), validação nos 25% finais (31.725; limiar por F1 máximo; Platt na validação). Limiares: logreg 0,1933, LightGBM 0,8558, Isolation Forest 0,6035.

**AUC e decisão no mundo B:**

| Decisor | AUC nosso→PixSim B | AUC PixSim A→B | Recall A→B | Fricção A→B | Custo A→B (R$/1.000) |
|---|---|---|---|---|---|
| Regressão logística | 0,770 | 0,990 | 64,7% | 0,8% | 53,39 |
| LightGBM | 0,580 | 0,989 | 73,0% | 1,0% | 59,12 |
| Isolation Forest | 0,788 | 0,850 | 8,0% | 1,4% | 157,88 |
| Regras | 0,740 | 0,740 | 51,1% | 3,1% | 118,82 |
| Regras + LightGBM | 0,718 | 0,987 | 80,9% | 3,6% | 99,42 |

*(Fonte: `validacao-pixsim.md`, "Modelos do caminho quente".)* "Regras + LightGBM" é a política em que as regras decidem e um score do LightGBM acima do limiar sobre um Pix aprovado vira 2FA: barra 80,9% dos Pix de vítima e custa R$ 99,42, contra R$ 118,82 das regras sozinhas ($-$16%). Os modelos sozinhos custam menos ainda, mas sem o motivo explicável que o enunciado pede. No sentido inverso (PixSim A → nosso simulador) o LightGBM cai a AUC 0,775 e 22,2% de recall, e as regras (AUC 0,965) ganham dos modelos. Captura por tipologia no mundo B com os modelos treinados no PixSim A: conta tomada 84,6% (LightGBM) e 91,9% (logreg); engenharia social 74,1% e 60,3%; QR adulterado 38,8% e 28,7%; Pix errado 27,8% e 16,7%.

**GraphSAGE** (nível de nó, grafo pagador→destino em janelas de 72 h; rótulo de nó = `is_mule` do PixSim, com 1.366 mulas no A e 1.321 no B):

| Modelo | Avaliado em | Nós alvo | AUC | Precisão | Recall | Fricção em destinos legítimos |
|---|---|---|---|---|---|---|
| Treinado no PixSim A | treino | 80.709 | 0,912 | 0,777 | 0,754 | 2,8% |
| Treinado no PixSim A | PixSim B | 82.682 | 0,919 | 0,786 | 0,787 | 2,5% |
| Treinado no nosso simulador | PixSim B | 82.682 | 0,518 | 0,241 | 0,005 | 0,2% |

**Leituras.** (i) Trocar a fonte de treino leva logreg e LightGBM de AUC 0,77 e 0,58 para 0,99. (ii) O 0,99 é otimista: os mundos A e B vêm do mesmo gerador, então mede generalização entre sementes, não independência; a seção 5.10 mostra que não há vazamento de rótulo, mas que parte do sinal vem de premissas do gerador. (iii) Pix errado (17% a 28% de captura) e QR adulterado (29% a 39%) continuam difíceis. (iv) O Isolation Forest treinado no PixSim melhorou o AUC (0,85 contra 0,79), mas o limiar p99 só captura 8,0%; o critério de troca não foi atendido e o `iforest.json` permanece o do simulador. (v) O GraphSAGE de AUC 0,92 é um teto: o rótulo é estático por conta e a janela contém os Pix pontuados. (vi) O HMM não foi avaliado no PixSim. Os JSON de logreg, LightGBM e GraphSAGE instalados no repositório vêm do PixSim A e seguem em *shadow*; o Isolation Forest e o HMM continuam os do nosso simulador; o `graphsage.json` do PixSim pontua abaixo de uma conta comum a mula do nosso simulador (conta nova, 10 pagadores), porque a mula do PixSim é uma conta antiga que recebe de vários pagadores e dispersa, e o teste de integração do worker foi reescrito para montar esse cenário (a asserção não mudou).

*Sobre a comparação com o artigo:* ver a seção 5.9; o AUC de 0,82 do escorer sintético do artigo não é comparável ao nosso 0,99.

## 6.7 Rótulos atrasados

O corte de treino $T$ é o fim do mundo A; uma fraude só vira positiva se `transaction_date + atraso de reporte` $\leq T$ e se foi reportada; as demais entram como legítimas. LightGBM com os mesmos hiperparâmetros, avaliado no mundo B com rótulos verdadeiros:

| Cenário de rótulo | Positivos conhecidos | AUC | Recall | Fricção | Custo R$/1.000 |
|---|---|---|---|---|---|
| Oráculo (todos os rótulos) | 1.380 de 1.380 | 0,989 | 73,0% | 1,0% | 59,12 |
| Atraso do PixSim (MED) | 1.083 de 1.380 | 0,968 | 65,4% | 0,7% | 71,06 |
| Atraso fixo de 3 dias | 1.254 de 1.380 | 0,989 | 61,6% | 0,5% | 62,68 |
| Atraso fixo de 7 dias | 1.061 de 1.380 | 0,989 | 63,0% | 0,5% | 61,78 |
| Atraso fixo de 14 dias | 723 de 1.380 | 0,657 | 11,3% | 0,9% | 159,56 |
| Atraso do PixSim, descartando os últimos 14 dias | 644 de 1.380 | 0,957 | 49,4% | 0,5% | 86,10 |

*(Fonte: `validacao-pixsim.md`, "Rótulos atrasados".)* Com o atraso real do MED (mediana de 2 dias, cauda de 17) o modelo perde pouco no AUC (0,989 para 0,968) e algum recall (73,0% para 65,4%), mas o custo sobe cerca de 20% (R$ 59,12 para R$ 71,06). O dano cresce rápido com o atraso fixo: 14 dias deixam o

modelo quase cego (AUC 0,657, recall 11,3%), porque os positivos recentes, mais parecidos com o tráfego de amanhã, viram "legítimos". Descartar os últimos 14 dias não recuperou nada com um mundo de 30 dias (R$ 86,10: jogou fora metade dos positivos). Na prática, retreinar com frequência e esperar a cauda do MED importa mais do que corrigir o prior.

## 6.8 Retroalimentação pelo MED

Simulada **só no backtest** (a API, o banco e as regras ativas não mudam; ADR 0032). O mundo B é reproduzido em ordem de `transaction_date`; cada fraude de vítima reportada gera um desfecho em `transaction_date` + atraso de reporte, aplicado ao histórico quando o relógio dos dados o alcança. Pix reprovado não liquida e não gera desfecho (viés de seleção); com 2FA, 10% escapam e geram desfecho. Peças: regra `COUNTERPARTY_CONFIRMED_FRAUD` (destino que recebeu fraude confirmada de outro pagador antes de $t$, pedindo 2FA, escolhido no mundo A por custar R$ 103,47 por 1.000 Pix contra R$ 225,28 de reprovar), LightGBM instalado como regra extra e retreino a cada 7 dias com promoção *champion/challenger*.

| Cenário | Custo R$/1.000 | Captura | Fricção em legítimos | Fraudes sem desfecho possível | Escapes confirmados |
|---|---|---|---|---|---|
| a) regras, sem retroalimentação | 118,82 | 51,1% | 3,1% | 47,6% | 597 |
| b) + sinal de fraude confirmada | 112,23 | 65,4% | 3,3% | 59,9% | 438 |
| c) + modelo campeão fixo | 100,84 | 84,5% | 3,8% | 77,4% | 195 |
| d) + retreino semanal | 103,18 | 80,7% | 3,7% | 73,9% | 233 |

*(Fonte: `validacao-pixsim.md`, "Retroalimentação pelo MED".)* Leituras: (1) o sinal de fraude confirmada é o ganho mais barato: −R$ 6,59 por 1.000 Pix e +14 pontos de captura; (2) o retreino semanal **piorou** o resultado: dois desafiantes custaram menos na semana de sombra e foram promovidos (semanas 1 e 2), mas nas semanas seguintes custaram mais do que o campeão original custaria, e o cenário fecha em R$ 103,18 contra R$ 100,84 do campeão fixo. Uma semana de sombra com fraude superamostrada é pouco para separar desafiante melhor de sorte, o mundo é estacionário e os rótulos maduros vêm censurados pelo próprio motor; (3) **viés de seleção**: 47,6% das fraudes (ponderadas) já não geram desfecho com as regras, e 77,4% com o campeão decidindo; a precisão do 2FA vista pelos desfechos (0,01% a 0,04% por semana) fica cerca de dez vezes abaixo da real (0,15% a 0,23%), e a de reprovação é zero por construção, então monitorar só por rótulo subestima o que o motor acerta; (4) limites: 4 retreinos em 30 dias, fraude superamostrada e custo semanal ruidoso.

## 6.9 Peer group: medido e descartado

`PROFILE_PEER_AMOUNT` comparava o valor de um pagador sem perfil próprio (menos de 5 Pix em 30 dias) com os de pares do mesmo grupo (PF/PJ × idade da conta; até 500 valores, mínimo 50), com z robusto $> 3{,}5$ (nível 2 de Bolton & Hand). Medida com as 18 regras e os parâmetros anteriores à calibração: antes e depois, no mundo B e no nosso simulador, fricção, captura e custo foram **idênticos** (R$ 157,60 por 1.000 Pix no B): só 12 dos 1.438 Pix de vítima (0,8%) vêm de pagador sem perfil, com z mediano de 1,7, abaixo do corte. A latência pela API (300 mil Pix em 30 dias) seria +9 ms com grupo cheio e +94 ms com grupo vazio. A regra **não entra no motor** (ADR 0028); o pagador novo continua coberto pelas regras de payload e de velocidade fixa.

## 6.10 Latência

| Medida | Valor | Fonte |
|---|---|---|
| Motor em memória (sem HTTP), 254.795 Pix | P50 0,33 ms; P95 0,60 ms; P99 0,84 ms; 2.710 Pix/s | `validacao-pixsim.md`, "Latência do backtest" |
| Backtest em lote completo | 101,7 s (2.506 Pix/s) | idem |
| Três modelos em *shadow* | +149 $\mu$s por Pix | ADR 0024 |
| Pela API, 300 mil Pix em 30 dias | média de 50 ms por Pix com histórico e 59 ms por pagador novo (medida no experimento do grupo de pares) | `validacao-pixsim.md`, "Peer group" |

A latência do motor é dominada pelas consultas de histórico, não pelas regras; os agregados são *range scans* em índice (seção 3.5).

## 6.11 Deriva das características

O PSI do nosso gerador contra o PixSim é muito alto em características geográficas (8,3, porque o PixSim não tem geolocalização) e de histórico (o *burn-in* de 30 dias contra 14 dias do nosso), o que é artefato de construção. O que sobra de informação real: valor (`amount`, PSI 0,74), idade da conta de origem (0,87) e, em Pix de vítima, `destination_age_days` (4,39, coerente com `COUNTERPARTY_NEW_ACCOUNT` em zero no PixSim). Entre os mundos A e B, 0 características passam de 0,1 considerando todos os Pix e considerando só a fraude: duas amostras do mesmo gerador não derivam (*fonte: `validacao-pixsim.md`, "PSI"; `analises.md`, análise 3*).

## 6.12 Contribuição de cada regra (ablação)

Mundo B, visão pagador, 127.683 legítimos e 1.438 Pix de vítima, custo com falso bloqueio de R$ 50 + 2%, versão `2026.10.18-pixsim-2`. Linha de base com as 15 regras: **R$ 118,82 por 1.000 Pix**, 51,1% dos Pix de vítima barrados, 3,09% de 2FA e 0,00% de reprovação em legítimos. "Contribuição" é o custo sem a regra (as outras 14 ligadas, `backtest.py --disable`) menos o custo com todas: positiva, a regra economiza. A ablação é marginal: duas regras que cobrem o mesmo Pix aparecem ambas com contribuição baixa.

| Regra | Disparo em legítimos | Disparo em vítimas | Contribuição (R$/1.000 Pix) | Vítima barrada sem a regra | Veredito |
|---|---|---|---|---|---|
| `COUNTERPARTY_FIRST_TIME_HIGH` | 1,28% | 32,7% | +34,63 | 27,7% | contribui |
| `PROFILE_NEW_DEVICE` | 0,002% | 15,0% | +5,60 | 40,8% | contribui |
| `VELOCITY_POISSON_GAMMA` | 0,14% | 6,8% | +3,77 | 45,3% | contribui |
| `TYPOLOGY_ACCOUNT_TAKEOVER` | 0,000% | 1,0% | +0,31 | 51,1% | contribui |
| `PROFILE_NEW_SOURCE_ACCOUNT` | 0,000% | 0,1% | +0,18 | 51,0% | contribui |
| `VELOCITY_SOURCE_COUNT`, `VELOCITY_DEVICE_SOURCES`, `PROFILE_GEO_VELOCITY`, `COUNTERPARTY_FAN_IN`, `COUNTERPARTY_GRAPH_RISK` | 0,00% | 0,0% | 0,00 | 51,1% | nunca dispara no PixSim |
| `LIMIT_SINGLE_AMOUNT` | 1,022% | 0,0% | $-$0,22 | 51,1% | ruído (único teto de exposição por Pix) |
| `TYPOLOGY_MULE` | 0,001% | 0,0% | $-$0,39 | 51,1% | custa mais com ela (âncora: art. 39-B, §1º, II) |
| `PROFILE_AMOUNT_ROBUST_Z` | 0,712% | 1,0% | $-$1,54 | 50,9% | custa mais com ela (âncora: Iglewicz & Hoaglin) |
| `LIMIT_NIGHT_AMOUNT` | 0,568% | 4,6% | $-$6,52 | 50,2% | custa mais com ela (âncora: Res. BCB 142/2021) |

| Regra | Disparo em legítimos | Disparo em vítimas | Contribuição (R$/1.000 Pix) | Vítima barrada sem a regra | Veredito |
|---|---|---|---|---|---|
| COUNTERPARTY_NEW_ACCOUNT | 0,0% | 1,1% | $-$25,38 | 50,6% | custa mais com ela (âncora: art. 39-B, §1º, II) |

*(Fonte: `validacao-pixsim.md`, "Contribuição de cada regra", regerada com as 15 regras.)* **Leitura.** Cinco regras pagam o próprio custo no PixSim, e uma delas (`COUNTERPARTY_FIRST_TIME_HIGH`) responde por quase tudo: sem ela, os Pix de vítima barrados caem de 51,1% para 27,7%. Cinco nunca disparam, porque o PixSim não gera o sinal que elas procuram (seção 5.11); `TYPOLOGY_MULE` dispara uma única vez, num legítimo, e `LIMIT_SINGLE_AMOUNT` em 28 legítimos. Das cinco de contribuição negativa, quatro ficam por âncora regulatória ou estatística (critério 2 da ADR 0033). `LIMIT_SINGLE_AMOUNT` fica por outro motivo (ADR 0033): com 18 regras a contribuição era nula, os R$ 0,22 de agora estão abaixo de R$ 1 por 1.000 Pix, que nesta escala é ruído, e ela é o único teto de exposição por Pix do motor. A maior negativa, `COUNTERPARTY_NEW_ACCOUNT`, custa mais porque as mulas do PixSim são contas de idade comum e a regra pede 2FA a legítimos que pagam contas novas. O PixSim mede o que o seu gerador desenhou: ausência de efeito aqui não prova ausência de efeito em Pix real. As três regras que tinham contribuição negativa sem âncora saíram do motor (seção 4.2.7).

**Sensibilidade (mundo B, um parâmetro por vez).** O parâmetro de maior efeito é a idade mínima da conta de destino (`RULE_DESTINATION_MIN_AGE_DAYS`, compartilhado com `TYPOLOGY_MULE`): 15 dias custariam R$ 102,73 e 60 dias R$ 164,54, contra R$ 118,82 com 30. O valor mínimo do primeiro Pix para um destino troca captura por fricção: R$ 500 barra 71,7% dos Pix de vítima a R$ 125,85; R$ 3.000 barra 36,1% a R$ 124,23. O limite noturno de R$ 2.000 custaria R$ 114,02, mas o corte fica no limite regulatório de R$ 1.000. Baixar o mínimo de pagadores de `TYPOLOGY_MULE` de 5 para 3 custaria R$ 131,35. Os demais parâmetros mexem o custo em no máximo R$ 2,00. Nenhum parâmetro mudou por esta medida, que é do mundo B, e não do mundo que escolhe.

## 6.13 Cascata de valor

Roda o relógio do MED do próprio PixSim sobre as decisões do nosso motor no mundo B regerado. `approved` liquida; `rejected` bloqueia; `two_factor_required` em fraude bloqueia com probabilidade 0,9 e liquida no restante; em legítimo, o 2FA é confirmado e liquida. "Perdido" é a perda de valor de vítima depois da recuperação pelo MED e pelo bloqueio cautelar.

| Política | Barrado antes | Retido num salto | Recuperado pelo MED | Recuperado por bloqueio cautelar | Perdido | Falsos bloqueios | Dano dos falsos bloqueios |
|---|---|---|---|---|---|---|---|
| `pass_all` (nosso mundo B) | 0,0% | 0,0% | 6,1% | 14,6% | 79,3% | 0 | R$ 0 |
| Regras | 66,1% | 6,6% | 1,9% | 4,7% | 20,7% | 2 | R$ 513 |
| Regras + LightGBM decidindo | 86,6% | 1,5% | 0,4% | 2,5% | 9,0% | 2 | R$ 513 |
| `threshold_block` do PixSim (escorer deles) | 68,5% | 26,1% | 0,4% | 7,0% | 3,0% | 485 | R$ 33.487 |

*(Fonte: `validacao-pixsim.md`, "Cascata de valor".)* Sem barrar nada, 79% do valor se perde; as regras sozinhas deixam perder 21%, e com o LightGBM decidindo, 9%. O `threshold_block` do PixSim perde só 3%, mas com 485 falsos bloqueios contra 2 das regras (eram 36 antes do descarte das três regras, quase todos do `TYPOLOGY_SPLITTING`). Esta linha vem de outro mundo gerado, com o escorer deles (AUC de

vítima 0,998), e serve de ordem de grandeza, não de comparação Pix a Pix. O custo em reais da seção 2.9 trata fraude aprovada como perda total do valor; a cascata mostra que parte volta, então o custo é um limite superior da perda.

## 6.14 Sensibilidade à qualidade do escorer

Réplica do experimento S7 do PixSim sobre os modelos que já temos, sem retreinar: o score ganha ruído gaussiano no logit, $\text{logit}(p') = \text{logit}(p) + \mathcal{N}(0, \sigma)$. O ruído só existe neste experimento, não nos nossos modelos nem no escorer padrão do PixSim. Mundo B, as regras decidem e o modelo acima do limiar sobre um Pix aprovado vira 2FA; as regras sozinhas custam R$ 118,82.

| $\sigma$ (LightGBM) | AUC ponderada | Custo por 1.000 Pix | Fricção em legítimos | Custo com limiar de mesma fricção |
|---|---|---|---|---|
| 0 | 0,989 | R$ 99,42 | 3,6% | R$ 99,42 |
| 3 | 0,978 | R$ 111,68 | 4,0% | R$ 108,85 |
| 6 | 0,924 | R$ 167,07 | 6,7% | R$ 120,00 |
| 8 | 0,873 | R$ 246,64 | 10,6% | R$ 123,73 |
| 12 | 0,788 | R$ 414,65 | 19,0% | R$ 127,81 |

*(Fonte: `validacao-pixsim.md`, "Sensibilidade à qualidade do scorer".)* O AUC de 0,82 corresponde a $\sigma \approx 10{,}3$ para o LightGBM (e $\approx 7{,}2$ para a logística). Nesse ponto, com o limiar reajustado, o custo é R$ 127,08 (LightGBM) e R$ 122,93 (logística): **sem ganho sobre as regras** (R$ 118,82); com o limiar original do modelo, a fricção em legítimos vai a 15,7% e 16,8%. O ganho do modelo (cerca de $-$16% sem ruído) só existe enquanto o AUC fica acima de aproximadamente 0,9; um escorer de 0,82 não paga a fricção que causa. Ressalva: o ruído é gaussiano e independente do Pix, o que degrada o score de forma mais uniforme do que um modelo treinado com características piores.

# 7 Limitações e trabalhos futuros

**Limitações medidas ou conhecidas.**

- **Dado sintético.** O PixSim reflete hipóteses dos autores, calibradas com dados agregados do BCB, não casos reais. Os números medem fricção e custo *relativo* entre configurações.
- **Uma geração, duas sementes.** Os mundos A e B vêm do mesmo gerador; a generalização medida é entre amostras. Não há intervalo de confiança; só uma semente por mundo.
- **Taxa de escape do 2FA.** Premissa de 10% sem fonte; 69,6% do valor das vítimas cai em 2FA, e acima de ~40% de escape o motor custa mais do que aprovar tudo (`validacao-pixsim.md`, "Sensibilidade à taxa de escape do 2FA").
- **Escala reduzida.** 5.025 contas e 30 dias, contra 1,08 milhão de contas no artigo; fraude superamostrada (o P@$k$ é inflado).
- **Sinais que o PixSim não gera.** Geolocalização, IP, fazenda de aparelhos, rajada na conta da vítima, funil de vítimas na mesma hora e fracionamento não existem no PixSim (seção 5.11); `PROFILE_GEO_VELOCITY`, `VELOCITY_SOURCE_COUNT`, `VELOCITY_DEVICE_SOURCES`, `COUNTERPARTY_FAN_IN`, `COUNTERPARTY_GRAPH_RISK` e a parte geográfica da tipologia de conta tomada só têm como evidência os testes pela API e o nosso simulador. Documento, IP, agência e conta são sintéticos.
- **Vieses do gerador.** Sem vazamento de rótulo detectado (seção 5.10), mas o AUC de 0,99 vem de premissas do PixSim (medianas de valor da fraude assumidas; só o valor já dá 0,937); o limite noturno embutido na conta tomada e os 19% de Pix de vítima em exatamente R$ 999,99 ou R$ 1.000,00 deixam duas regras cegas por construção; e o mundo B, usado na ablação e na escolha dos modelos, não é mais teste puro.
- **Família Montante sem regra.** A soma diária foi descartada (seção 4.2.7); fracionamento real só é coberto em parte pelo teto por Pix, pelo z robusto e, no nosso simulador, pelo 2FA de outras regras.
- **Só o lado do banco pagador.** A dispersão foi tratada à parte, pois exige a mula ser cliente.
- **Cold path fora do backtest.** Grafo, GraphSAGE e HMM não rodaram no backtest em lote do PixSim (os scores são `None`); o HMM mostrou pouco sinal sem eventos de sessão.
- **Parâmetros de custo são hipóteses de negócio** (ADR 0030), e o custo absoluto depende deles.
- **Paridade em amostra.** API e backtest comparados em 500 Pix.

**Trabalhos futuros.**

1. **Rota de desfechos do MED.** `POST /pix/transaction/{id}/outcome` e uma tabela `pix_outcome` fecham o ciclo de aprendizado em produção (ADR 0032); saem do contrato do enunciado e por isso foram simuladas só no backtest. O sinal de fraude confirmada é o primeiro candidato a ir para a API.
2. **Feature store em escala.** O histórico por SQL com índices escala até algumas centenas de milhares de Pix; em dezenas de milhares de Pix por segundo a pesquisa aponta *streaming* (padrão Scarff [10]: Kafka, Flink e Redis) para manter janelas deslizantes.
3. **Escala do banco.** Particionamento por data e consultas de grupo vazio (+94 ms) pedem tratamento antes de volumes reais.
4. **Rótulos reais.** Substituir o PixSim por desfechos do MED e contestações transforma o mesmo processo de backtest em backtest real e permite calibrar o prior, o limiar e o custo de verdade.
5. **Eventos de sessão.** Login, troca de limite e cadastro de chave dariam sentido ao HMM ou a uma rede recorrente.
6. **Zona cinzenta por modelo de linguagem.** A pesquisa descreve um avaliador semântico de passagem única para os casos atípicos que passam pelas regras e pelo grafo; fora do escopo e da latência desta entrega (ADR 0017).
7. **Inferência de rejeitados.** Corrigir o treino pelo viés de seleção das fraudes barradas.

# 8 Como reproduzir

Pré-requisitos: Docker com `docker compose`, Git, Python 3.11 (ou `uv`) e, para este PDF, `pandoc` (3.x) e `xelatex` com as fontes FreeSerif e DejaVu.

```
git clone <repositorio> && cd Hackathon
make all                  # sobe api, db e worker, espera healthy, cria .venv 3.11 e
 ↪  roda o pytest
make reset check          # recria o banco, lint (flake8) e testes; precisa passar
 ↪  antes de qualquer entrega
```

A API responde em `http://localhost:3000`; toda rota, menos `/` e `/health_check`, exige `INTERNAL-TOKEN: default_token`.

```
curl -X POST http://localhost:3000/pix/transaction \
  -H "INTERNAL-TOKEN: default_token" -H "Content-Type: application/json" \
  -d @docs/03-api/exemplo-pix.json
curl http://localhost:3000/pix/transaction/pix-000123 -H "INTERNAL-TOKEN:
 ↪  default_token"
```

`make` sem argumento lista todos os alvos. Os do dia a dia:

| Comando | Faz |
|---|---|
| `make up`, `make down`, `make logs` | sobe api, db e worker (religa o worker parado pelo `make test`); para; acompanha o log |
| `make test`, `make lint`, `make check` | os 113 testes *black box* (com o worker parado; os testes chamam um ciclo); `flake8`; os dois |
| `make reset`, `make rebuild` | recria o banco (depois de mudar `database/database.sql`); reconstrói a imagem (depois de mudar `requirements.txt`) |
| `make pdf` | compila este relatório |

Ferramentas de risco (rodam fora da API; as do PixSim precisam de `make pixsim-datasets` antes):

| Comando | Faz |
|---|---|
| `make pixsim` | clona o PixSim (SHA fixo), cria o venv próprio e gera um mundo reduzido (A por padrão; B com `PIXSIM_SEED=20261017 PIXSIM_OUT=scripts/out/pixsim/data-b`) |
| `make pixsim-datasets` | gera os mundos A e B (se faltarem) e exporta as características de treino e teste |
| `make validate-pixsim` | adaptador, backtest e relatório (atualiza `docs/05-motor/validacao-pixsim.md`) |
| `make rule-ablation` | ablação por regra e sensibilidade no mundo B (retoma do cache; atualiza `validacao-pixsim.md`) |
| `make calibrate-pixsim` | grid pelo custo ponderado: escolhe no A, confirma no B |
| `make pixsim-parity` | paridade API × backtest em 500 Pix do PixSim (zera o banco) |
| `make analyze` | análises estatísticas (`docs/05-motor/analises.md`) |
| `make train-models`, `make train-graphsage`, `make train-hmm` | retreina os modelos em *shadow* e instala os JSON em `src/rules/models/artifacts/` e `src/worker/models/artifacts/` |
| `make model-parity` | compara os avaliadores em Python puro com `scikit-learn` e `lightgbm` |
| `make delayed-labels`, `make feedback` | rótulos atrasados e retroalimentação pelo MED (atualizam `validacao-pixsim.md`) |
| `make simulate`, `make parity`, `make calibrate-check` | nosso simulador, a paridade dele e a trava de regressão do CI (fixture, sem valor estatístico); `make reset` depois |

Não rode o simulador enquanto a suíte de testes roda: os testes zeram o banco. `make test` para o worker para que os testes controlem cada ciclo; `make up` religa.

**Do clone ao PDF.**

```
make pdf                # docs/relatorio/relatorio.md -> docs/relatorio/relatorio.pdf
```

O alvo `pdf` roda `pandoc` com `--pdf-engine=xelatex --toc --number-sections -V lang=pt-BR`, lendo `metadata.yaml` (título, autores, geometria A4, fontes) e `relatorio.md`; as figuras são os PNG de `docs/02-arquitetura/diagramas/`.

# 9 Perguntas prováveis da banca

Preparação para a apresentação. Cada resposta é curta, cita o número que a sustenta e aponta onde está o detalhe. Números do PixSim são do mundo B (confirmação) salvo indicação; custo é o ponderado por 1.000 Pix.

## 9.1 O problema e a decisão

**Por que regras explícitas decidem, e não um modelo?** Não há rótulo real de fraude no hackathon. Regra é explicável (o `reason` diz o porquê ao cliente e ao analista), reproduzível e auditável, e resolve o *cold start*. Os modelos existem, mas em *shadow*: calculam e gravam, nunca mudam a decisão (ADR 0017, 0022). No PixSim, regras + LightGBM custariam R$ 99,42 contra R$ 118,82 só com regras; isso só seria levado a produção com rótulo real.

**Por que `rejected` não é erro HTTP?** Reprovar é uma decisão de negócio sobre um Pix válido, não uma falha da requisição. A resposta é 201 com `status: rejected`; erro (4xx) fica para payload inválido, conflito de `id` (409, QIT002002) ou análise inexistente (404, QIT002001) (ADR 0003).

**Como várias regras viram uma decisão? Dois 2FA não somam uma reprovação?** Todas as regras rodam; vence a mais severa (`rejected` > `two_factor_required` > `approved`) e todos os disparos vão para `metadata.reasons`. Dois sinais de dúvida não viram reprovação: só uma tipologia explícita (conta tomada, mula) ou um sinal extremo reprova (ADR 0006, 0018).

**Por que a maioria das regras pede 2FA em vez de reprovar?** Pelo custo assimétrico: 2FA em legítimo custa R$ 2 de atrito; reprovar legítimo custa R$ 50 + 2% do valor; fraude com 2FA escapa em 10% dos casos (vítima coagida confirma). Com isso, reprovar só compensa quando o risco é claro (ADR 0030).

## 9.2 Regras e calibração

**Como os parâmetros foram escolhidos?** Grid sobre o backtest no PixSim, minimizando o custo ponderado: o mundo A escolhe, o mundo B confirma. A calibração tirou o custo de R$ 127,26 para R$ 118,82 no mundo B com as regras atuais. Parâmetro só muda com evidência do PixSim; o nosso simulador é só *fixture* do CI (ADR 0029).

**Por que o limite noturno fica em R$ 1.000 se o PixSim preferia R$ 2.000?** É a âncora regulatória (Res. BCB 142/2021; IN BCB 512/2024): R$ 1.000 por conta das 20h às 6h para pessoa física. Manter custa cerca de R$ 4,80 por 1.000 Pix no mundo B. Parte disso é artefato do gerador: o PixSim já limita a conta tomada à noite a R$ 1.000, então a regra não consegue disparar nela.

**Por que três regras foram descartadas? A família "Montante" ficou sem regra?** `TYPOLOGY_SPLITTING`, `COUNTERPARTY_FLAGGED` e `AMOUNT_SOURCE_DAILY_SUM` tinham ablação negativa nos dois mundos e nenhuma âncora regulatória. Desligadas juntas, o custo caiu de R$ 132,13 para R$ 109,61 (mundo A) e de R$ 153,51 para R$ 118,82 (B), com 1 ponto a menos de vítimas barradas. Sim: Montante ficou sem regra própria; o teto por Pix e o z robusto cobrem parte (ADR 0033).

**Qual é a regra mais importante?** `COUNTERPARTY_FIRST_TIME_HIGH` (primeiro Pix do pagador para aquele destino acima de R$ 1.000): +R$ 34,63 por 1.000 Pix; sem ela, a captura de vítimas cai de 51,1% para 27,7%. Depois vêm `PROFILE_NEW_DEVICE` (+R$ 5,60) e `VELOCITY_POISSON_GAMMA` (+R$ 3,77).

**`COUNTERPARTY_NEW_ACCOUNT` custa R$ 25,38 a mais no PixSim. Por que fica?** Porque o art. 39-B, §1º, II do Regulamento do Pix manda considerar o tempo de abertura da conta do recebedor. No PixSim as mulas têm idade comum, então a regra só pega legítimos que pagam contas novas; em Pix real, conta laranja recém-aberta é padrão documentado. É a decisão registrada: âncora regulatória vence o gerador.

**E as regras que nunca disparam no PixSim?** São cinco: rajada do pagador, fazenda de aparelhos, viagem impossível, funil de vítimas e reputação de grafo. O PixSim não gera esses sinais (não tem geolocalização, usa um aparelho por conta, espalha vítimas no tempo, e o worker não roda no backtest). Elas custam zero lá, têm testes pela API e são exercitadas na trava do CI. Não inventamos geolocalização no adaptador para não medir a nossa própria invenção.

## 9.3 Validação

**Por que não validar com o próprio simulador?** Seria circular: nós desenhamos a fraude e as regras que a pegam. No nosso simulador as regras barravam 98,5% das vítimas; no PixSim, 51%. Por isso o nosso simulador ficou só como trava de regressão do CI, e todo número com valor estatístico vem do PixSim (ADR 0029).

**O PixSim é confiável?** É um gerador de terceiros (Apache-2.0), calibrado com dados abertos do BCB, com tipologias que não desenhamos e o relógio do MED. Mas é sintético e várias formas são premissas declaradas (`ASSUMED`). Rodamos em escala reduzida (5.025 contas, 30 dias, uma seed por mundo), então diferenças abaixo de cerca de R$ 1 por 1.000 Pix são ruído.

**Houve vazamento de dados (*data leakage*)?** De rótulo, não. O adaptador só passa campos do contrato; as features usam só o histórico passado (paridade API × backtest com 0 divergências); os mundos A e B são independentes (só 3 de 5.025 contas com a mesma data de abertura; mulas com o mesmo id no nível do acaso). Os valores "colados" do PixSim (R$ 999,99…) são 22% das fraudes, mas o modelo não depende deles (AUC 0,992 → 0,990 sem eles). O que existe é viés: o mundo B foi usado na ablação, por isso o descarte foi confirmado também no A.

**O AUC de 0,99 não é bom demais?** É otimista, e dizemos isso: A e B vêm do mesmo gerador, só muda a seed. Só o valor do Pix já dá AUC 0,937, porque as medianas de fraude são premissas do PixSim. No sentido inverso (treino no PixSim, teste no nosso simulador) o LightGBM cai a 0,78 e as regras ganham.

**Como vocês comparam com o artigo do PixSim?** Mesma perspectiva (banco pagador), mesmos positivos (Pix de vítima), mesmo peso de importância e mesmo custo de falso bloqueio (R$ 50 + 2%). Rodando o relógio do MED do próprio PixSim sobre as nossas decisões: sem política se perde 79,3% do valor; com as regras, 20,7%; com regras + LightGBM, 9,0%. O `threshold_block` do PixSim perde 3,0%, mas com 485 falsos bloqueios contra 2 das nossas regras.

**E se o modelo fosse pior, como um scorer real?** Replicamos o experimento de ruído do artigo (logit + ruído gaussiano). Com AUC 0,82, o LightGBM com limiar reajustado custa R$ 127,08 contra R$ 118,82 das regras: sem ganho. O modelo só paga a fricção que causa com AUC acima de cerca de 0,93.

**Como o motor protege contra engenharia social, se a própria vítima faz o Pix e pode confirmar o 2FA?** Em boa parte, não protege: é o ponto mais fraco. Na engenharia social nenhum Pix de vítima é reprovado; 46,9% recebem 2FA e 53,1% passam. O custo assume que só 10% das vítimas coagidas confirmam o 2FA, premissa sem fonte. Com 30% o custo vai a R$ 139,88; acima de ~40% o motor custa mais do que aprovar tudo (R$ 151,29). O que ajuda hoje: primeiro Pix alto para destino novo, rajada fora do ritmo, limite noturno e, depois do fato, MED, bloqueio cautelar e o sinal de destino com fraude confirmada. O que ajudaria mais: 2FA como alerta específico, retenção do primeiro Pix alto para destino novo, teto para destinatário novo e o lado do recebedor (DICT, art. 39-B).

## 9.4 Modelos e retroalimentação

**Como os modelos rodam no *hot path* sem scikit-learn na imagem?** Os modelos são treinados offline e exportados para JSON (pesos e árvores); a inferência é Python puro. A diferença contra a biblioteca é de ~1e-16 (LightGBM) a ~1e-15 (regressão logística), verificada por `make model-parity` (ADR 0024).

**Por que GraphSAGE e HMM ficam num worker separado?** Grafo e sequência pedem numpy e uma visão de muitos Pix; isso não cabe nos milissegundos do POST. O worker calcula a cada 30 s e grava o score; o *hot path* só lê o último score com até 120 min (ADR 0025, 0026). O GraphSAGE tem AUC de nó 0,92 no mundo B, otimista porque o rótulo `is_mule` é estático.

**Como fica o atraso do rótulo (MED)?** Treinando só com as fraudes já reportadas (mediana de 2 dias, cauda de 17), o AUC cai pouco (0,989 → 0,968) e o custo sobe ~20%. Com um atraso fixo de 14 dias o modelo fica quase cego (AUC 0,66): os positivos recentes, os mais úteis, viram "legítimos" (Dal Pozzolo et al., 2018).

**Como o banco aprenderia com os desfechos?** Simulamos no backtest, não na API (ADR 0032). O sinal "destino com fraude já confirmada no MED" é o ganho mais barato: R$ 118,82 → R$ 112,23 e captura de 51% → 65%. O retreino semanal com *champion/challenger* promoveu dois desafiantes que pioraram depois (R$ 103,18 contra R$ 100,84 do modelo fixo): uma semana de sombra não basta; em produção, exigiríamos margem ou mais tempo.

**O que é o viés de seleção?** Pix reprovado não liquida e não gera desfecho. Com o modelo decidindo, 77% das fraudes nunca geram rótulo, e a precisão do 2FA vista pelos desfechos fica ~10 vezes abaixo da real. Monitorar só por rótulo subestima o motor.

## 9.5 Engenharia

**Qual a latência e quanto aguenta?** O motor avalia um Pix em P50 0,33 ms e P95 0,60 ms (backtest em memória, ~2,7 mil Pix/s). Na API, o custo dominante são as consultas de janela no Postgres (índices por pagador, aparelho e destino). A API é sem estado e escala horizontalmente; não fizemos teste de carga, então não prometemos um número de Pix/s em produção.

**Como garantem que o backtest decide igual à API?** O motor só conhece o `HistoryPort`: em produção, SQL; no backtest, índices em memória. `make parity` manda o mesmo roteiro pelos dois e compara status, regras e as 33 features: 0 divergências (ADR 0023).

**Por que o "agora" é o `transaction_date` e não o relógio do servidor?** Para a decisão ser reproduzível: o mesmo Pix com o mesmo histórico sempre recebe a mesma resposta, no teste, no backtest e na reanálise (ADR 0007).

**E idempotência?** O mesmo `id` com o mesmo payload devolve a análise gravada (200). O mesmo `id` com payload diferente é conflito (409, QIT002002). Todo Pix é gravado, inclusive os reprovados; as tabelas são *append-only* e dinheiro é inteiro em centavos.

**Como testam?** 113 testes *black box* pela API, sem importar `src/` nem ler o banco: cada regra tem um teste que não dispara e um que dispara, mais cenários, contrato e idempotência. O CI roda lint, testes, paridade e a trava de calibração.

## 9.6 Próximos passos e processo

**O que fariam com dados reais?** (1) Rota de desfechos (`POST /pix/transaction/{id}/outcome`) para receber o MED; (2) consulta às notificações de infração do DICT no lugar da reputação derivada; (3) recalibrar no histórico real e só então tirar um modelo de *shadow*, com *champion/challenger* exigindo margem; (4) teste de carga.

**Como usaram IA no desenvolvimento?** Como ferramenta de engenharia, com regras explícitas no repositório: `AGENTS.md` (limites, TDD, camadas), *skills* por tarefa e um CHANGELOG em que toda

mudança de agente é marcada como tal. Decisões de produto (descartar regras, manter o limite noturno, o que é validação) foram do time e estão nas ADRs.

## Referências


[1] QI Tech. *Desafio Antifraude Pix* e slides de abertura do Hackathon QI Tech 2026 (Risk Solutions). Transcrição em `docs/01-contexto/enunciado.md`; PDFs em `docs/referencia/enunciado/`.

[2] Pesquisa QITech (documento interno do time, literatura branca e cinzenta). `docs/pesquisa/Pesquisa QITech.pdf`.

[3] Bolton, R. J.; Hand, D. J. (2002). *Statistical Fraud Detection: A Review*. Statistical Science, vol. 17.

[4] Pizzolato et al. (2025). *A Taxonomy of Pix Fraud in Brazil*. arXiv:2511.20902. https://arxiv.org/abs/2511.20902

[5] Zeimarani, B.; Khatib, A.; Mousavinasr, S.; Figueiredo, C. M. S. (2026). *PixSim: a calibrated open-source simulator of instant-payment fraud, recovery and interdiction under analyst capacity constraints*. arXiv:2609.30684. Código: https://github.com/BashirZeimarani/pixsim_public (Apache-2.0; commit `7fdfc90013960f46df60c3ea01838e768e7a420a`).

[6] Dal Pozzolo, A.; Caelen, O.; Johnson, R. A.; Bontempi, G. (2015). *Calibrating Probability with Undersampling for Unbalanced Classification*. IEEE CIDM.

[7] Dal Pozzolo, A. et al. (2018). *Credit card fraud detection: a realistic modeling and a novel learning strategy*. IEEE Transactions on Neural Networks and Learning Systems, 29(8).

[8] Dal Pozzolo, A. et al. (2014). *Learned lessons in credit card fraud detection from a practitioner perspective*. Expert Systems with Applications, 41(10).

[9] Lucas, Y. et al. (2019). *Multiple perspectives HMM-based feature engineering for credit card fraud detection*. ACM SAC 2019.

[10] Carcillo, F. et al. (2018). *Scarff: a scalable framework for streaming credit card fraud detection with Spark*. Information Fusion 41, 182-194. doi:10.1016/j.inffus.2017.09.005

[11] Banco Central do Brasil. Resolução BCB nº 142/2021, art. 2º, I (limite noturno de R$ 1.000, 20h às 6h, pessoa física), hoje consolidado na Resolução BCB nº 512/2024, art. 3º, §3º e §7º, II.

[12] Banco Central do Brasil. Regulamento do Pix, arts. 37 e 39-B, §1º, I a V (fatores de avaliação de suspeita, como tempo desde a abertura da conta e recorrência; o 39-B trata do PSP do recebedor).

[13] Documentação e decisões do projeto: `docs/02-arquitetura/decisoes/` (ADRs 0001 a 0033), `docs/05-motor/` (regras, calibração, validação no PixSim, análises) e `scripts/backtest/cost-model.json`.

[14] Iglewicz, B.; Hoaglin, D. C. (1993). *How to Detect and Handle Outliers*. ASQC Quality Press (escore z modificado com mediana e MAD; resumo no NIST/SEMATECH e-Handbook, seção 1.3.5.17).